Relatório executivo

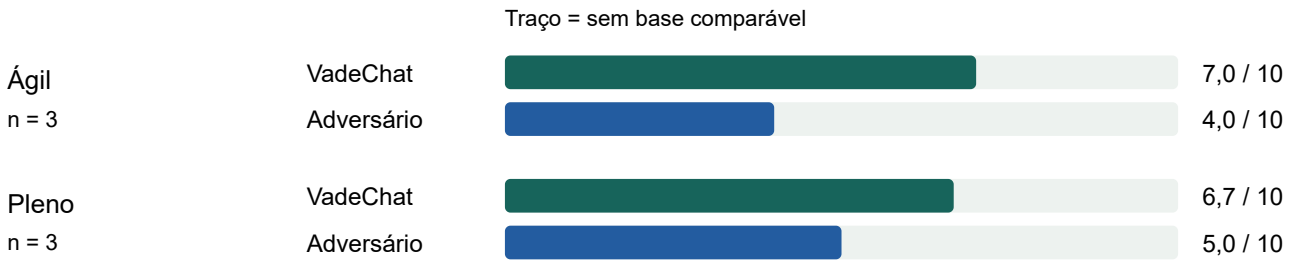
GPT-5.4 Mini com raciocínio ativado · Ágil e Pleno · Rodada 1

Rodada final · 3 perguntas · Ágil e Pleno · run-2026-10-28-f0e7a09c-c3a3-4441-8fba-f2bc93d8028d

relalia-442-pair/1 · série original · 2026-10-28. VadeChat nos modos selecionados; identidades disponíveis abaixo.

Papel	Participante / plataforma	Modelo declarado
Adversário	OpenAI	openai/gpt-5.4-mini
Juiz	OpenRouter API	anthropic/claude-sonnet-5.5
Revisor	OpenRouter API	openai/gpt-5.4-mini
Ágil	VadeChat	
Pleno	VadeChat	

Resultados por modo

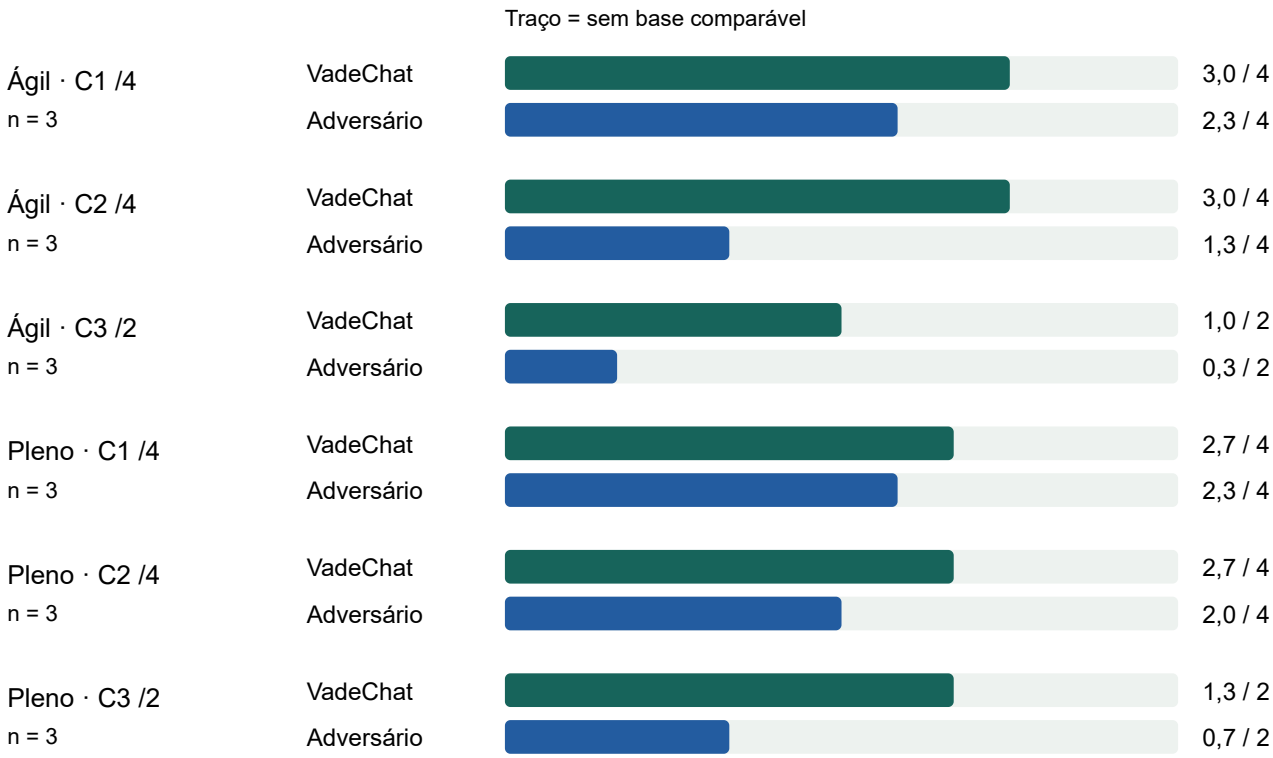


Médias de embates comparáveis; adversário separado contra cada modo.

Modo	Média V / A	V / E / D	Cobertura	Pend. / inconcl. / desat.
Ágil	7,0 / 4,0	3 / 0 / 0	3/3 (100%)	0 / 0 / 0
Pleno	6,7 / 5,0	2 / 0 / 1	3/3 (100%)	0 / 0 / 0

V / A: VadeChat / adversário. V / E / D: vitórias / empates / derrotas do VadeChat. Desatualizados já incluídos nos inconclusivos. Ausência não é zero. 0 embates fora das médias. Modos não selecionados não geram pendência.

Qualidade e revisão



C1: conclusão e orientação prática /4; C2: fundamentação e informações essenciais /4; C3: condições, limites e ressalvas /2. Cada critério exige notas presentes nos dois lados; n indicado no gráfico.

Modo	Contradições V / A	Abstenções V / A	Revisões	Contestações / decisões pendentes
Ágil	0 / 0	0 / 0	3/3; 0 pendentes	0 / 0
Pleno	0 / 0	0 / 0	3/3; 0 pendentes	0 / 0

Contradições: avaliações por série com condição essencial contrariada nos embates comparáveis. Abstenções dos participantes avaliáveis mantêm zero conforme o protocolo. Revisões não alteram notas. Vencer por pontos não significa conformidade. Informação adicional não verificável não é tratada como erro.

Base e limitações

As médias usam os mesmos embates atuais e comparáveis nos dois lados. Pendências, resultados inconclusivos e desatualizados são excluídos. As séries Ágil e Pleno não são promediadas.

Envio manual é declaração do usuário, não prova independente.

Avaliação semântica e pertinência das evidências exigem revisão.

Séries adversárias por modo e tentativas experimentais não são promediadas.

Este benchmark não sustenta superioridade geral. Evidências, versões, prompts e histórico permanecem no aplicativo e no relatório técnico completo. Nomes extensos são abreviados neste executivo.

Consumo e custo disponíveis

Papel / tentativas	Tokens entrada / saída / total	Informado pelo provedor	Estimativa sem custo informado	Duração
Adversário **3 tentativas; 0 falhas/incertas**	111 / 3.391 / 3.502 0 tentativas com dados incompletos	US$ 0,015343 0 custos desconhecidos	—	29,8 s 0 sem duração
Juiz **8 tentativas; 2 falhas/incertas**	76.601 / 21.725 / 98.326 0 tentativas com dados incompletos	US$ 0,370452 0 custos desconhecidos	—	151,9 s 0 sem duração
Revisor **8 tentativas; 2 falhas/incertas**	47.482 / 23.559 / 71.041 0 tentativas com dados incompletos	US$ 0,132123 0 custos desconhecidos	—	165,3 s 0 sem duração

Subtotais dos dados disponíveis no plano atual; falhas com consumo registrado incluídas. Adversário compartilhado contado uma vez por tentativa. Duração soma tentativas; cache e raciocínio não são somados novamente aos tokens. Registro manual não informa consumo. Estimativa não é cobrança nem limite garantido; tarifas não informadas podem ficar de fora.

Orçamento local OpenRouter: US$ 1,000000 · consumo/reservas: US$ 0,517918 · saldo após reservas: US$ 0,482082.

Orçamento usa todas as tentativas da execução, inclusive planos anteriores, como o controle existente. Saldo da conta do provedor não é consultado neste relatório.

Geração Tri7: Ágil: 27 tentativas; tokens entrada/saída desconhecido/desconhecido; duração desconhecida; custo desconhecido; Pleno: 3 tentativas; tokens entrada/saída desconhecido/desconhecido; duração desconhecida; custo desconhecido.

Conclusões deste benchmark

1. Ágil: média 7,00 contra 4,00 em 3 embates; 3 vitórias, 0 empates e 0 derrotas.
2. Pleno: média 6,67 contra 5,00 em 3 embates; 2 vitórias, 0 empates e 1 derrota.
3. 0 de 6 embates fora das médias por pendência, inconclusão ou desatualização.
4. 0 avaliações do VadeChat e 0 avaliações do adversário com contradição essencial, contando as duas séries, nos embates comparáveis.
5. 0 revisões ou decisões pendentes. Revisões não alteram notas.

Consolidação determinística, sem chamadas de IA. Execução 2cd6b748-5665-413f-8251-f14483606d29 · revisão 501. O relatório é parcial enquanto houver avaliações, revisões ou decisões necessárias sem conclusão.