Relatório executivo

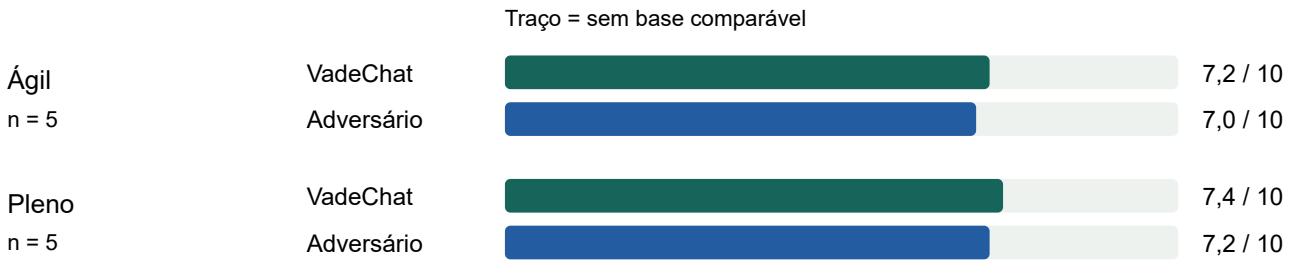
OpenAI / openai/gpt-6.1-sol · Ágil e Pleno · Rodada 1

Rodada parcial · 5 perguntas · Ágil e Pleno · run-2026-11-03-44ef15f6-2b46-409e-b888-73c4b3775aeb

relalia-442-pair/1 · série original · 2026-11-03. VadeChat nos modos selecionados; identidades disponíveis abaixo.

Papel	Participante / plataforma	Modelo declarado
Adversário	OpenAI	openai/gpt-6.1-sol
Juiz	Anthropic	anthropic/claude-sonnet-5.5
Revisor	OpenAI	openai/gpt-5.4-mini
Ágil	VadeChat	
Pleno	VadeChat	

Resultados por modo



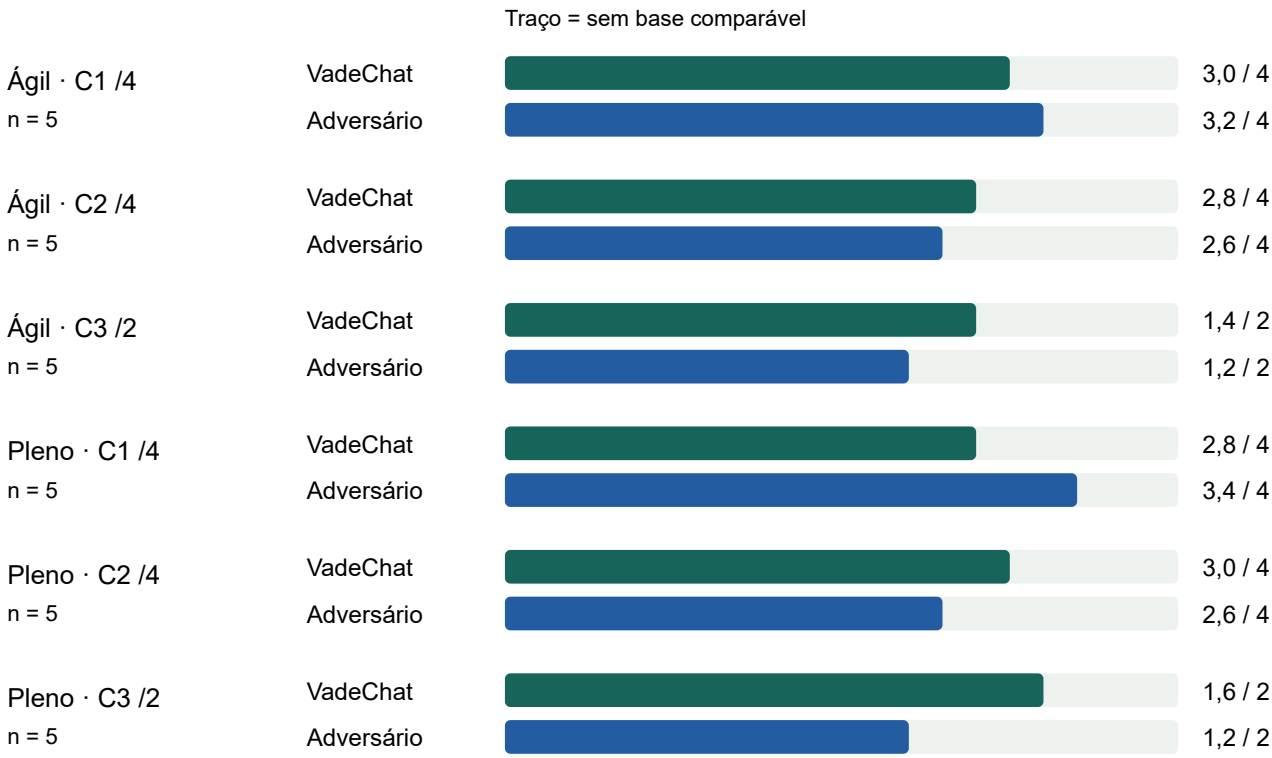
Médias de embates comparáveis; adversário separado contra cada modo.

Modo	Média V / A	V / E / D	Cobertura	Pend. / inconcl. / desat.
Ágil	7,2 / 7,0	2 / 1 / 2	5/5 (100%)	0 / 0 / 0
Pleno	7,4 / 7,2	3 / 0 / 2	5/5 (100%)	0 / 0 / 0

V / A: VadeChat / adversário. V / E / D: vitórias / empates / derrotas do VadeChat. Desatualizados já incluídos nos inconclusivos. Ausência não é zero. 0 embates fora das médias. Modos não selecionados não geram pendência.

- Ágil: 2 contestações (2 decisões pendentes).
- Pleno: 1 contestação (1 decisão pendente).

Qualidade e revisão



C1: conclusão e orientação prática /4; C2: fundamentação e informações essenciais /4; C3: condições, limites e ressalvas /2. Cada critério exige notas presentes nos dois lados; n indicado no gráfico.

Modo	Contradições V / A	Abstenções V / A	Revisões	Contestações / decisões pendentes
Ágil	0 / 0	0 / 0	5/5; 0 pendentes	2 / 2
Pleno	0 / 0	0 / 0	5/5; 0 pendentes	1 / 1

Contradições: avaliações por série com condição essencial contrariada nos embates comparáveis. Abstenções dos participantes avaliáveis mantêm zero conforme o protocolo. Revisões não alteram notas. Vencer por pontos não significa conformidade. Informação adicional não verificável não é tratada como erro.

Base e limitações

As médias usam os mesmos embates atuais e comparáveis nos dois lados. Pendências, resultados inconclusivos e desatualizados são excluídos. As séries Ágil e Pleno não são promediadas.

Envio manual é declaração do usuário, não prova independente.

Avaliação semântica e pertinência das evidências exigem revisão.

Séries adversárias por modo e tentativas experimentais não são promediadas.

Este benchmark não sustenta superioridade geral. Evidências, versões, prompts e histórico permanecem no aplicativo e no relatório técnico completo. Nomes extensos são abreviados neste executivo.

Consumo e custo disponíveis

Papel / tentativas	Tokens entrada / saída / total	Informado pelo provedor	Estimativa sem custo informado	Duração
Adversário **5 tentativas; 0 falhas/incertas**	198 / 4.351 / 4.549 0 tentativas com dados incompletos	US$ 0,043906 0 custos desconhecidos	—	136,4 s 0 sem duração
Juiz **10 tentativas; 0 falhas/incertas**	109.013 / 27.293 / 136.306 0 tentativas com dados incompletos	US$ 0,490956 0 custos desconhecidos	—	188,7 s 0 sem duração
Revisor **13 tentativas; 3 falhas/incertas**	84.105 / 2.357 / 86.462 0 tentativas com dados incompletos	US$ 0,045519 0 custos desconhecidos	—	38,4 s 0 sem duração

Subtotais dos dados disponíveis no plano atual; falhas com consumo registrado incluídas. Adversário compartilhado contado uma vez por tentativa. Duração soma tentativas; cache e raciocínio não são somados novamente aos tokens. Registro manual não informa consumo. Estimativa não é cobrança nem limite garantido; tarifas não informadas podem ficar de fora.

Orçamento local OpenRouter: US$ 1,000000 · consumo/reservas: US$ 0,580381 · saldo após reservas: US$ 0,419619.

Orçamento usa todas as tentativas da execução, inclusive planos anteriores, como o controle existente. Saldo da conta do provedor não é consultado neste relatório.

Geração Tri7: Ágil: 5 tentativas; tokens entrada/saída desconhecido/desconhecido; duração desconhecida; custo desconhecido; Pleno: 5 tentativas; tokens entrada/saída desconhecido/desconhecido; duração desconhecida; custo desconhecido.

Conclusões deste benchmark

1. Ágil: média 7,20 contra 7,00 em 5 embates; 2 vitórias, 1 empate e 2 derrotas.
2. Pleno: média 7,40 contra 7,20 em 5 embates; 3 vitórias, 0 empates e 2 derrotas.
3. 0 de 10 embates fora das médias por pendência, inconclusão ou desatualização.
4. 0 avaliações do VadeChat e 0 avaliações do adversário com contradição essencial, contando as duas séries, nos embates comparáveis.
5. 3 revisões ou decisões pendentes. Revisões não alteram notas.

Consolidação determinística, sem chamadas de IA. Execução 45c7b893-4b1b-4c44-ad41-49fc80f8c445 · revisão 347. O relatório é parcial enquanto houver avaliações, revisões ou decisões necessárias sem conclusão.