Relatório executivo

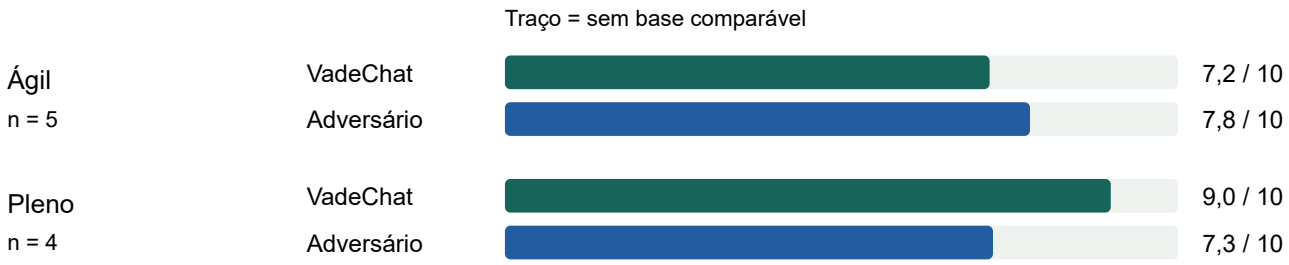
Anthropic / anthropic/claude-sonnet-5.5 · Ágil e Pleno · Rodada 1

Rodada final · 5 perguntas · Ágil e Pleno · run-2026-11-04-1f77e6ea-affb-40ae-83a1-9d79610986e4

relalia-442-pair/1 · série original · 2026-11-04. VadeChat nos modos selecionados; identidades disponíveis abaixo.

Papel	Participante / plataforma	Modelo declarado
Adversário	Anthropic	anthropic/claude-sonnet-5.5
Juiz	OpenAI	openai/gpt-5.6-sol
Revisor	OpenAI	openai/gpt-5.6-sol
Ágil	VadeChat	
Pleno	VadeChat	

Resultados por modo



Médias de embates comparáveis; adversário separado contra cada modo.

Modo	Média V / A	V / E / D	Cobertura	Pend. / inconcl. / desat.
Ágil	7,2 / 7,8	1 / 0 / 4	5/5 (100%)	0 / 0 / 0
Pleno	9,0 / 7,3	2 / 0 / 2	4/5 (80%)	0 / 0 / 0

V / A: VadeChat / adversário. V / E / D: vitórias / empates / derrotas do VadeChat. Desatualizados já incluídos nos inconclusivos. Ausência não é zero. 1 embate fora das médias. Modos não selecionados não geram pendência.

- Ágil: 3 contestações (0 decisões pendentes).
- Pleno: 2 contestações (0 decisões pendentes).

Julgamento derivado · correção literal de um caractere

Pleno · cobertura direta 4/5 · cobertura com o derivado 5/5. As médias e os indicadores da série direta usam os julgamentos diretos.

Q04 · Pleno · VadeChat 9,0 × adversário 9,0. Q04 · Revisão Pleno · Endossada. Tentativa rejeitada de origem 6ec43b78-37f1-4682-b785-fb9aae4cddba. Campo A.criteria.c2.evidence.2.responseQuote. Inicial O → o.

Condições da recuperação seletiva

Resultados anteriores preservados. Condições alteradas por trabalho; o agregado não é uma comparação homogênea.

Recuperação c7955345-a57a-4fd2-8633-c0a489f661b8 · plano 7ad76cd0-4eca-4bd1-bb9a-121e865b5b5f · Corrigir citações literais e teto de saída, preservando resultados válidos.

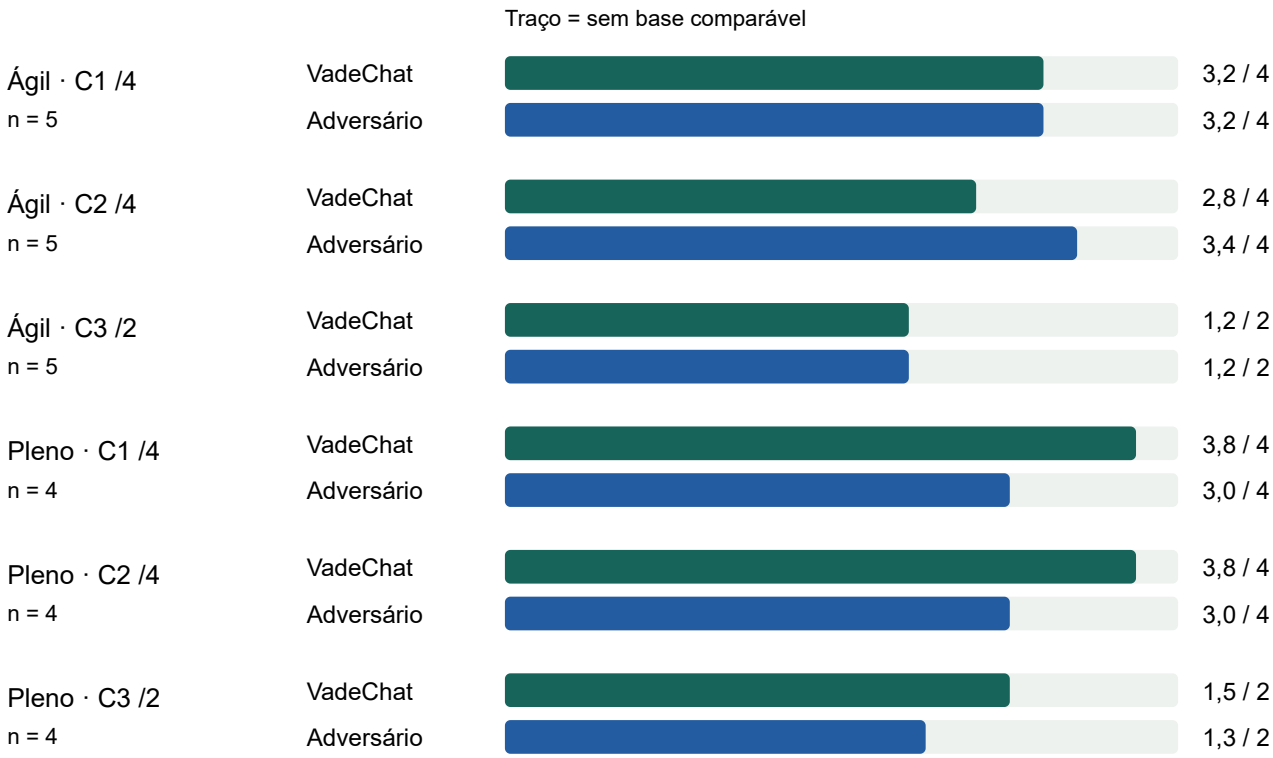
- Q01 judgment agil: modelo openai/gpt-5.6-sol-20260709; rota openai; saída 8192 → 8192; raciocínio sem configuração explícita; prompt literal-citations/2.
- Q01 review agil: modelo openai/gpt-5.6-sol-20260709; rota openai; saída 8192 → 8192; raciocínio sem configuração explícita; prompt original.
- Q01 judgment pleno: modelo openai/gpt-5.6-sol-20260709; rota openai; saída 8192 → 8192; raciocínio sem configuração explícita; prompt literal-citations/2.
- Q01 review pleno: modelo openai/gpt-5.6-sol-20260709; rota openai; saída 8192 → 8192; raciocínio sem configuração explícita; prompt original.
- Q04 opponent : modelo anthropic/claude-sonnet-5.5-20260928; rota anthropic; saída 4096 → 8192; raciocínio sem configuração explícita; prompt original.
- Q04 judgment agil: modelo openai/gpt-5.6-sol-20260709; rota openai; saída 8192 → 8192; raciocínio sem configuração explícita; prompt literal-citations/2.
- Q04 review agil: modelo openai/gpt-5.6-sol-20260709; rota openai; saída 8192 → 8192; raciocínio sem configuração explícita; prompt original.
- Q04 judgment pleno: modelo openai/gpt-5.6-sol-20260709; rota openai; saída 8192 → 8192; raciocínio sem configuração explícita; prompt literal-citations/2.
- Q04 review pleno: modelo openai/gpt-5.6-sol-20260709; rota openai; saída 8192 → 8192; raciocínio sem configuração explícita; prompt original.

Recuperação 9ce11227-4342-46b0-b525-0e9082bd8310 · plano 7ad76cd0-4eca-4bd1-bb9a-121e865b5b5f · Uma tentativa corretiva para as duas citações não literais da Q04 Pleno.

Tentativa rejeitada vinculada: 75f79715-2e06-4af8-9efb-ac879a67c39b. Prompt anterior 5ccfae01-af61-4bf9-9dcc-1a41bbc4a969 · SHA-256 3fafbaf871d6e7d2067c50735328fcb83deebdb5f8a878ffe30101411e7a214a.

- Q04 judgment pleno: modelo openai/gpt-5.6-sol-20260709; rota openai; saída 8192 → 8192; raciocínio sem configuração explícita; prompt literal-citations/2+q04-pleno-correction/1.
- Q04 review pleno: modelo openai/gpt-5.6-sol-20260709; rota openai; saída 8192 → 8192; raciocínio sem configuração explícita; prompt original.

Qualidade e revisão



C1: conclusão e orientação prática /4; C2: fundamentação e informações essenciais /4; C3: condições, limites e ressalvas /2. Cada critério exige notas presentes nos dois lados; n indicado no gráfico.

Modo	Contradições V / A	Abstenções V / A	Revisões	Contestações / decisões pendentes
Ágil	0 / 0	0 / 0	5/5; 0 pendentes	3 / 0
Pleno	0 / 0	0 / 0	4/4; 0 pendentes	2 / 0

Contradições: avaliações por série com condição essencial contrariada nos embates comparáveis. Abstenções dos participantes avaliáveis mantêm zero conforme o protocolo. Contestações são revisões válidas dos julgamentos principais; concluir a fila ou corrigir formatação não registra uma decisão. Revisões não alteram notas. Vencer por pontos não significa conformidade. Informação adicional não verificável não é tratada como erro.

Base e limitações

As médias usam os mesmos embates atuais e comparáveis nos dois lados. Pendências, resultados inconclusivos e desatualizados são excluídos. As séries Ágil e Pleno não são promediadas.

Execução com recuperação seletiva: condições de prompt e/ou teto de saída alteradas e identificadas por trabalho. O agregado é descritivo e não comprova homogeneidade entre condições.

Julgamentos derivados têm cobertura separada e ficam fora do agregado de julgamentos diretos.

Envio manual é declaração do usuário, não prova independente.

Avaliação semântica e pertinência das evidências exigem revisão.

Séries adversárias por modo e tentativas experimentais não são promediadas.

Este benchmark não sustenta superioridade geral. Evidências, versões, prompts e histórico permanecem no aplicativo e no relatório técnico completo. Nomes extensos são abreviados neste executivo.

Consumo e custo disponíveis

Papel / tentativas	Tokens entrada / saída / total	Informado pelo provedor	Estimativa sem custo informado	Duração
Adversário **8 tentativas; 0 falhas/incertas**	1.094 / 25.208 / 26.302 0 tentativas com dados incompletos	US$ 0,254268 0 custos desconhecidos	—	222,4 s 0 sem duração
Juiz **20 tentativas; 11 falhas/incertas**	117.765 / 46.329 / 164.094 0 tentativas com dados incompletos	US$ 1,321657 0 custos desconhecidos	—	458,6 s 0 sem duração
Revisor **10 tentativas; 0 falhas/incertas**	74.638 / 12.294 / 86.932 0 tentativas com dados incompletos	US$ 0,619040 0 custos desconhecidos	—	170 s 0 sem duração

Subtotais dos dados disponíveis no plano atual; falhas com consumo registrado incluídas. Adversário compartilhado contado uma vez por tentativa. Duração soma tentativas; cache e raciocínio não são somados novamente aos tokens. Registro manual não informa consumo. Estimativa não é cobrança nem limite garantido; tarifas não informadas podem ficar de fora.

Orçamento local OpenRouter: US$ 8,000000 · consumo/reservas: US$ 3,003178 · saldo após reservas: US$ 4,996822.

Orçamento usa todas as tentativas da execução, inclusive planos anteriores, como o controle existente. Saldo da conta do provedor não é consultado neste relatório.

Geração Tri7: Ágil: 5 tentativas; tokens entrada/saída desconhecido/desconhecido; duração desconhecida; custo desconhecido; Pleno: 5 tentativas; tokens entrada/saída desconhecido/desconhecido; duração desconhecida; custo desconhecido.

Conclusões deste benchmark

1. Ágil: média 7,20 contra 7,80 em 5 embates; 1 vitória, 0 empates e 4 derrotas.
2. Pleno: média 9,00 contra 7,25 em 4 embates; 2 vitórias, 0 empates e 2 derrotas.
3. 1 de 10 embates fora das médias por pendência, inconclusão ou desatualização ou por derivação registrada.
4. 0 avaliações do VadeChat e 0 avaliações do adversário com contradição essencial, contando as duas séries, nos embates comparáveis.
5. 0 revisões ou decisões pendentes. Revisões não alteram notas.

Consolidação determinística, sem chamadas de IA. Execução d90728ec-7acd-4237-bb22-702cddbc2987 · revisão 892. O relatório é parcial enquanto houver avaliações, revisões ou decisões necessárias sem conclusão.