Relatório executivo

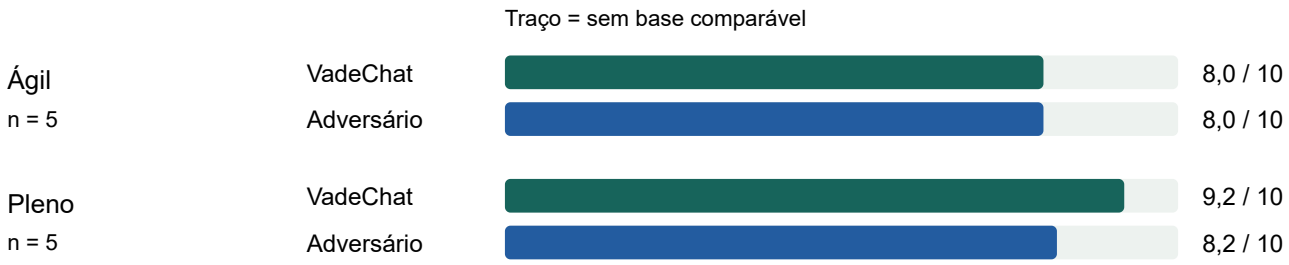
Google / google/gemini-3.8-flash · Ágil e Pleno · Rodada 1

Rodada final · 5 perguntas · Ágil e Pleno · run-2026-11-06-8ee15979-872e-46e5-8fe1-e56ef730e5d6

relalia-442-pair/1 · série original · 2026-11-06. VadeChat nos modos selecionados; identidades disponíveis abaixo.

Papel	Participante / plataforma	Modelo declarado
Adversário	google	google/gemini-3.8-flash
Juiz	OpenAI	openai/gpt-6.1-sol
Revisor	Anthropic	anthropic/claude-sonnet-5.5
Ágil	VadeChat	
Pleno	VadeChat	

Resultados por modo



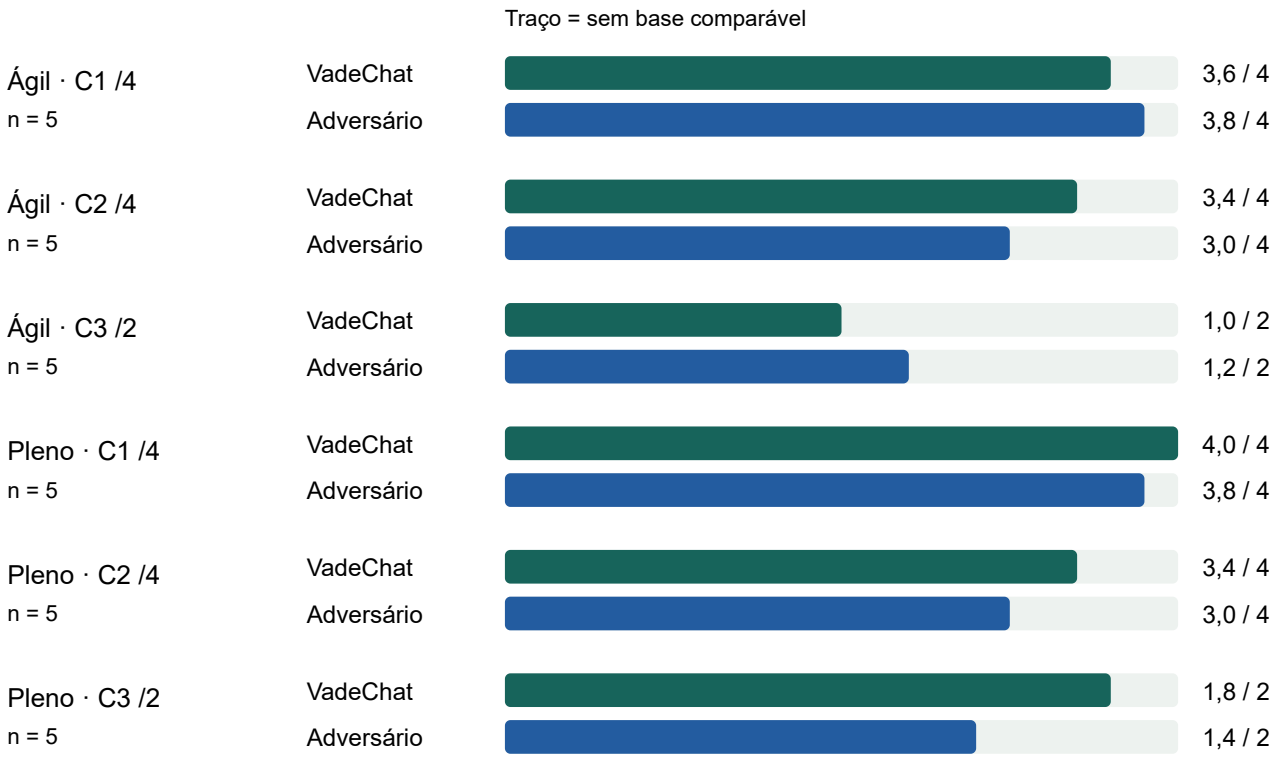
Médias de embates comparáveis; adversário separado contra cada modo.

Modo	Média V / A	V / E / D	Cobertura	Pend. / inconcl. / desat.
Ágil	8,0 / 8,0	2 / 1 / 2	5/5 (100%)	0 / 0 / 0
Pleno	9,2 / 8,2	2 / 1 / 2	5/5 (100%)	0 / 0 / 0

V / A: VadeChat / adversário. V / E / D: vitórias / empates / derrotas do VadeChat. Desatualizados já incluídos nos inconclusivos. Ausência não é zero. 0 embates fora das médias. Modos não selecionados não geram pendência.

- Ágil: 2 contestações (0 decisões pendentes).
- Pleno: 1 contestação (0 decisões pendentes).

Qualidade e revisão



C1: conclusão e orientação prática /4; C2: fundamentação e informações essenciais /4; C3: condições, limites e ressalvas /2. Cada critério exige notas presentes nos dois lados; n indicado no gráfico.

Modo	Contradições V / A	Abstenções V / A	Revisões	Contestações / decisões pendentes
Ágil	0 / 0	0 / 0	5/5; 0 pendentes	2 / 0
Pleno	0 / 0	0 / 0	5/5; 0 pendentes	1 / 0

Contradições: avaliações por série com condição essencial contrariada nos embates comparáveis. Abstenções dos participantes avaliáveis mantêm zero conforme o protocolo. Contestações são revisões válidas dos julgamentos principais; concluir a fila ou corrigir formatação não registra uma decisão. Revisões não alteram notas. Vencer por pontos não significa conformidade. Informação adicional não verificável não é tratada como erro.

Base e limitações

As médias usam os mesmos embates atuais e comparáveis nos dois lados. Pendências, resultados inconclusivos e desatualizados são excluídos. As séries Ágil e Pleno não são promediadas.

Envio manual é declaração do usuário, não prova independente.

Avaliação semântica e pertinência das evidências exigem revisão.

Séries adversárias por modo e tentativas experimentais não são promediadas.

Este benchmark não sustenta superioridade geral. Evidências, versões, prompts e histórico permanecem no aplicativo e no relatório técnico completo. Nomes extensos são abreviados neste executivo.

Consumo e custo disponíveis

Papel / tentativas	Tokens entrada / saída / total	Informado pelo provedor	Estimativa sem custo informado	Duração
Adversário **5 tentativas; 0 falhas/incertas**	191 / 9.670 / 9.861 0 tentativas com dados incompletos	US$ 0,036406 0 custos desconhecidos	—	96,4 s 0 sem duração
Juiz **10 tentativas; 0 falhas/incertas**	52.561 / 10.043 / 62.604 0 tentativas com dados incompletos	US$ 0,231817 0 custos desconhecidos	—	158,2 s 0 sem duração
Revisor **10 tentativas; 0 falhas/incertas**	87.149 / 10.342 / 97.491 0 tentativas com dados incompletos	US$ 0,277718 0 custos desconhecidos	—	125 s 0 sem duração

Subtotais dos dados disponíveis no plano atual; falhas com consumo registrado incluídas. Adversário compartilhado contado uma vez por tentativa. Duração soma tentativas; cache e raciocínio não são somados novamente aos tokens. Registro manual não informa consumo. Estimativa não é cobrança nem limite garantido; tarifas não informadas podem ficar de fora.

Orçamento local OpenRouter: US$ 8,000000 · consumo/reservas: US$ 0,545941 · saldo após reservas: US$ 7,454059.

Orçamento usa todas as tentativas da execução, inclusive planos anteriores, como o controle existente. Saldo da conta do provedor não é consultado neste relatório.

Geração Tri7: Ágil: 5 tentativas; tokens entrada/saída desconhecido/desconhecido; duração desconhecida; custo desconhecido; Pleno: 5 tentativas; tokens entrada/saída desconhecido/desconhecido; duração desconhecida; custo desconhecido.

Conclusões deste benchmark

1. Ágil: média 8,00 contra 8,00 em 5 embates; 2 vitórias, 1 empate e 2 derrotas.
2. Pleno: média 9,20 contra 8,20 em 5 embates; 2 vitórias, 1 empate e 2 derrotas.
3. 0 de 10 embates fora das médias por pendência, inconclusão ou desatualização.
4. 0 avaliações do VadeChat e 0 avaliações do adversário com contradição essencial, contando as duas séries, nos embates comparáveis.
5. 0 revisões ou decisões pendentes. Revisões não alteram notas.

Consolidação determinística, sem chamadas de IA. Execução 04d25e25-0763-4586-93e3-d36bb6b6082b · revisão 331. O relatório é parcial enquanto houver avaliações, revisões ou decisões necessárias sem conclusão.