Benchmark VadeChat × ChatGPT 6.1 Sol

VadeChat · 2026-11-03 · Execução finalizada

Síntese de resultados · complementar ao original

Resultados da rodada de 03/11/2026, finalizada conforme confirmação do executor: o VadeChat apresenta média 0,20 ponto acima do GPT-6.1 Sol nos dois modos, com vitórias e derrotas em ambos. A síntese destaca os critérios e as prioridades para a equipe de IA.

Execução finalizada, conforme confirmação do executor em 03/11/2026, após sucesso na reexecução das três verificações afetadas por erro inicial.

Resultados do benchmark · fonte de 03/11/2026

OpenAI / openai/gpt-6.1-sol · Ágil e Pleno · Rodada 1

5 perguntas · 10 embates comparáveis · escala 0-10. Médias e resultados originais do juiz.

VadeChat Ágil 7,20

VadeChat Ágil · 7,20 / 10

GPT-6.1 Sol · 7,00 / 10

Diferença: +0,20 pontos · n = 5

VadeChat Pleno 7,40

VadeChat Pleno · 7,40 / 10

GPT-6.1 Sol · 7,20 / 10

Diferença: +0,20 pontos · n = 5

Modo	VadeChat	GPT-6.1 Sol	V / E / D	Comparáveis
Ágil	7,20	7,00	2 / 1 / 2	5/5
Pleno	7,40	7,20	3 / 0 / 2	5/5

Médias com duas casas conforme as conclusões da p. 4. Diferenças calculadas sobre as médias publicadas, com cinco embates por modo. Critérios arredondados na fonte; não recalculamos os totais a partir desses valores.

Amostra de cinco perguntas, sem validação jurídica independente nesta síntese. Diferença de média não demonstra superioridade geral.

Onde os pontos foram obtidos

Critério	Máximo	Ágil · VC / adversário	Pleno · VC / adversário
C1 · Conclusão e orientação prática	4	3,0 / 3,2	2,8 / 3,4
C2 · Fundamentação e informações essenciais	4	2,8 / 2,6	3,0 / 2,6
C3 · Condições, limites e ressalvas	2	1,4 / 1,2	1,6 / 1,2

Base por modo e critério: Ágil n = 5; Pleno n = 5. Médias arredondadas por critério não devem ser somadas para reconstruir os totais.

Prioridades para a equipe de IA

Síntese editorial dos agregados; não constitui novo julgamento.

Conclusão e orientação prática: Em C1, o VadeChat ficou abaixo do adversário: 3,0 contra 3,2 no Ágil e 2,8 contra 3,4 no Pleno, de 4 pontos possíveis. C2 e C3 compensam essa diferença nos totais. A prioridade editorial é examinar as orientações práticas nos pareceres individuais antes de propor ajustes.

Aprofundar as revisões: As dez revisões estão concluídas, mas seus comentários não acompanham o executivo. A leitura dos pareceres individuais é necessária para identificar ressalvas e orientar ajustes na IA, sem alterar automaticamente notas e vencedores.

Média maior com resultados mistos: A diferença das médias é de +0,20 ponto nos dois modos. O Ágil tem duas vitórias, um empate e duas derrotas; o Pleno, três vitórias e duas derrotas. Esses agregados não indicam ganho uniforme. Para explicar as quatro derrotas nos dez embates, são necessários os pareceres e as respostas correspondentes.

Papéis e limites

Produto avaliado · Ágil e Pleno: VadeChat · modelo interno não informado.

Adversário: OpenAI · openai/gpt-6.1-sol. Identificado no título desta publicação como ChatGPT 6.1 Sol. Modalidade de acesso, login e nível de raciocínio não informados no anexo.

Juiz: Anthropic · anthropic/claude-sonnet-5.5.

Revisor: OpenAI · openai/gpt-5.4-mini. Papel separado do adversário. As dez revisões estão concluídas. O encerramento da execução foi confirmado pelo executor.

Ágil · registro do PDF: Revisões 5/5 (0 pendentes); contestações 2; decisões pendentes 2. Contradições essenciais VC/adversário: 0/0; abstenções: 0/0. Julgamentos pendentes/inconclusivos/desatualizados: 0/0/0.

Pleno · registro do PDF: Revisões 5/5 (0 pendentes); contestações 1; decisões pendentes 1. Contradições essenciais VC/adversário: 0/0; abstenções: 0/0. Julgamentos pendentes/inconclusivos/desatualizados: 0/0/0.

Revisões não substituem as notas originais. Vencer em pontos não equivale à classificação Conforme. Ausência de sinalização não comprova ausência de erros.

Operação e consumo

Papel	Tentativas / falhas ou incertas	Tokens totais	US$ provedor	Durações somadas
Adversário	5 / 0	4.549	0,043906	136,4 s
Juiz	10 / 0	136.306	0,490956	188,7 s
Revisor	13 / 3	86.462	0,045519	38,4 s

Geração Tri7: Ágil 5 tentativas; Pleno 5 tentativas. Tokens, custo e duração não informados. Tentativas não representam perguntas avaliadas.

Subtotais disponíveis do plano atual, com falhas de consumo registrado incluídas e adversário compartilhado contado uma vez por tentativa. Duração é a soma das tentativas, não latência da resposta. Tokens de cache e raciocínio não são somados novamente. Custos, tokens e duração da geração Tri7 são desconhecidos; estes valores não representam o custo total do VadeChat.

Fonte preservada: https://relalia.github.io/originals/reports/benchmark-chatgpt-sol-2026-11-03-results-reexportado.pdf

O PDF reenviado ainda registra o rótulo de parcial e três decisões como pendentes. O executor informou que a primeira tentativa teve erro, as três verificações passaram na reexecução e a rodada foi concluída. As contagens desta seção reproduzem o registro do PDF; o status de execução da publicação segue a confirmação do executor. Não foram fornecidos pareceres individuais ou registros de decisões para uma conferência adicional.