Benchmark VadeChat × Claude Sonnet 5.5

VadeChat · 2026-11-04 · Rodada parcial

Síntese de resultados · complementar ao original

Na rodada de 04/11/2026, o Claude Sonnet 5.5 teve média maior contra o VadeChat Ágil. O VadeChat Pleno obteve média maior em quatro embates diretos, com duas vitórias e duas derrotas.

Rodada parcial. Cinco contestações aguardam decisão. O empate derivado da Q04 Pleno (9,00 a 9,00) está fora das médias e do placar diretos.

Resultados do benchmark · fonte de 04/11/2026

Anthropic / anthropic/claude-sonnet-5.5 · Ágil e Pleno · Rodada 1

5 perguntas · 9 embates comparáveis · escala 0-10. Médias e resultados originais do juiz.

VadeChat Ágil 7,20

VadeChat Ágil · 7,20 / 10

Claude Sonnet 5.5 · 7,80 / 10

Diferença: -0,60 pontos · n = 5

VadeChat Pleno 9,00

VadeChat Pleno · 9,00 / 10

Claude Sonnet 5.5 · 7,25 / 10

Diferença: +1,75 pontos · n = 4

Modo	VadeChat	Claude Sonnet 5.5	V / E / D	Comparáveis
Ágil	7,20	7,80	1 / 0 / 4	5/5
Pleno	9,00	7,25	2 / 0 / 2	4/5

Médias com duas casas conforme as conclusões da p. 5. Os valores por critério seguem o arredondamento da fonte e podem somar valores diferentes das médias totais.

Amostra de cinco perguntas com condições de execução que variaram durante a recuperação seletiva. Os resultados descrevem esta rodada.

Onde os pontos foram obtidos

Critério	Máximo	Ágil · VC / adversário	Pleno · VC / adversário
C1 · Conclusão e orientação prática	4	3,2 / 3,2	3,8 / 3,0
C2 · Fundamentação e informações essenciais	4	2,8 / 3,4	3,8 / 3,0
C3 · Condições, limites e ressalvas	2	1,2 / 1,2	1,5 / 1,3

Base por modo e critério: Ágil n = 5; Pleno n = 4. Médias arredondadas por critério não devem ser somadas para reconstruir os totais.

Prioridades para a equipe de IA

Síntese editorial dos agregados; não constitui novo julgamento.

Fundamentação no Ágil: A diferença nas médias por critério está em C2, com 2,8 para o VadeChat e 3,4 para o Claude. Os dois lados têm a mesma média em C1 e C3.

Cobertura do Pleno: O VadeChat liderou a média por 1,75 ponto, com duas vitórias e duas derrotas. A fonte registra a Q04 separadamente após corrigir a inicial de uma citação literal. A cobertura passa de 4/5 diretos para 5/5 com o derivado.

Contestações em aberto: As nove revisões da série direta foram concluídas. Três contestações do Ágil e duas do Pleno aguardam decisão. As notas publicadas seguem o registro do juiz.

Papéis e limites

Produto avaliado · Ágil e Pleno: VadeChat · modelo interno não informado.

Adversário: Anthropic · anthropic/claude-sonnet-5.5.

Juiz: OpenAI · openai/gpt-5.6-sol.

Revisor: OpenAI · openai/gpt-5.6-sol.

Ágil · registro do PDF: Revisões 5/5 (0 pendentes); contestações 3; decisões pendentes 3. Contradições essenciais VC/adversário: 0/0; abstenções: 0/0. Julgamentos pendentes/inconclusivos/desatualizados: 0/0/0.

Pleno · registro do PDF: Revisões 4/4 (0 pendentes); contestações 2; decisões pendentes 2. Contradições essenciais VC/adversário: 0/0; abstenções: 0/0. Julgamentos pendentes/inconclusivos/desatualizados: 0/0/0.

Revisões não substituem as notas originais. Vencer em pontos não equivale à classificação Conforme. Ausência de sinalização não comprova ausência de erros.

Operação e consumo

Papel	Tentativas / falhas ou incertas	Tokens totais	US$ provedor	Durações somadas
Adversário	8 / 0	26.302	0,254268	222,4 s
Juiz	20 / 11	164.094	1,321657	458,6 s
Revisor	10 / 0	86.932	0,619040	170,0 s

Geração Tri7: Ágil 5 tentativas; Pleno 5 tentativas. Tokens, custo e duração não informados. Tentativas não representam perguntas avaliadas.

Os subtotais cobrem as tentativas do plano atual, inclusive as falhas com consumo registrado. A duração é a soma das tentativas. Os custos da geração Tri7 são desconhecidos.

Fonte preservada: https://relalia.github.io/originals/reports/benchmark-claude-sonnet-5-5-2026-11-04-results.pdf

A p. 2 do PDF executivo registra as condições da recuperação seletiva. O resultado derivado da Q04 Pleno e a revisão endossada têm cobertura separada.