# Reteste VadeChat × ChatGPT - Run 02 comparado à execução inicial

Execuções: 09/10/2026 (legado01) e 14/10/2026 (run02).

Q02 responde por +1,0 dos +1,2 pontos de aumento da média do Ágil (5 pontos ÷ 5 perguntas). As respostas fixas do ChatGPT receberam notas diferentes em cinco dos dez embates entre as execuções. O avanço de cobertura mais claro ocorre em Q02; a regressão mais clara ocorre em Q04 do Pleno. Isso não demonstra melhoria geral nem atribui toda variação ao VadeChat.

Cinco perguntas, comparadas em dois modos em cada execução. As notas medem concordância com a referência humana, sem validação jurídica independente. As revisões não substituem os resultados originais.

| Modo | Média 09/10 | Média 14/10 | Variação | Subiram / caíram / iguais |
|---|---|---|---|---|
| Ágil | 4,6 | 5,8 | +1,2 | 3 / 2 / 0 |
| Pleno | 7,4 | 6,8 | -0,6 | 2 / 2 / 1 |

## Dez comparações de notas originais

| Questão | Modo | VC antes | VC nova | Variação | Mudança principal |
|---|---|---|---|---|---|
| Q01 | Ágil | 2,0 | 3,0 | +1,0 | Retira lista extensa de documentos; persistem omissões e mistura com Registro Civil. |
| Q01 | Pleno | 5,0 | 6,0 | +1,0 | Acrescenta 90 dias; perde firma reconhecida, regime de bens e pacto. |
| Q02 | Ágil | 2,0 | 7,0 | +5,0 | Adota R$ 100 mil e a distinção entre análise especial e comunicação obrigatória. |
| Q02 | Pleno | 4,0 | 7,0 | +3,0 | Recupera hipóteses dos arts. 155-A e 162, antes não localizadas. |
| Q03 | Ágil | 10,0 | 9,0 | -1,0 | Mantém 180 dias; acrescenta 30 dias para outro documento, com desconto questionado. |
| Q03 | Pleno | 10,0 | 10,0 | 0,0 | Mantém 180 dias; mudam ressalvas e informações adicionais. |
| Q04 | Ágil | 1,0 | 3,0 | +2,0 | Acrescenta CPC e dois meses; segue pagamento em vez de declaração em 60 dias. |
| Q04 | Pleno | 8,0 | 2,0 | -6,0 | Perde CPC e declaração em 60 dias; trata pagamento e contradiz o próprio prazo. |
| Q05 | Ágil | 8,0 | 7,0 | -1,0 | Ganha lista de campos; perde identificação de Goiás; persistem ressalvas ausentes. |
| Q05 | Pleno | 10,0 | 9,0 | -1,0 | Ganha data e sinal público; perde vedação, diligência e biometria recomendada. |

Médias de cinco notas por modo e execução, sem arredondamento intermediário. Ausência não vira zero. Q05 permanece no resumo histórico, com a inconclusividade solicitada pelo revisor destacada.

Resultados originais do VadeChat (vitórias/empates comuns/derrotas): Ágil 1/1/3 para 1/0/4; Pleno 2/2/1 para 2/1/2. Sem abstenções ou resultados inconclusivos originalmente atribuídos.

## Conferência de integridade

Iguais byte a byte por SHA-256: cinco perguntas, cinco referências humanas integrais, cinco respostas do ChatGPT, global_prompt.txt, answer_alternation.txt e cinco registros locais de A/B. Nos materiais comparados não houve diferença restrita a codificação ou quebras de linha.

Fatos obrigatórios e pesos permanecem nos textos humanos de Q01, Q04 e Q05, com peso 1,00 em cada um. Q02 e Q03 não registram listas de fatos/pesos. Os campos separados facts e referencePrompt estão vazios nas duas execuções: ausência não foi tratada como zero. A escala-base é 4 + 4 + 2 = 10; não há regra adicional registrada para converter o peso dos fatos em pontos.

As dez respostas do VadeChat, dez julgamentos e dez revisões diferem em conteúdo, inclusive após normalização de BOM e fins de linha. Nenhuma nova resposta do VadeChat é idêntica à anterior. Identificadores e metadados mudaram legitimamente.

Os cinco adversários têm reutilização declarada no histórico de run02, vinculada à execução, registro e versão do legado. Esses vínculos e hashes foram conferidos. Q01-Q04 têm salvamentos posteriores sem repetir o metadado reused, mas conservam o mesmo hash; Q03 tem seis versões iguais do adversário. A procedência aqui é declarada pelo executor e corroborada pelos vínculos, sem comprovação externa de geração.

A/B permaneceu: ChatGPT como A em Q01/Q03/Q05; VadeChat como A em Q02/Q04, nos dois modos. O legado mantém mappingConfirmed=false: a atribuição foi conferida com answer_alternation.txt e os conteúdos descritos nos pareceres. Em run02, os prompts vinculados, seus textos A/B e dependências confirmam a correspondência.

Configurações declaradas iguais: juiz Claude Sonnet 5.5 Médio, acesso Grátis; revisor ChatGPT 6.1 Sol Alto, acesso Pago. Participante ChatGPT: Grátis, modelo não registrado, apesar de unidentified=false no formulário. Modelos internos do VadeChat, condições de sessão e versão do sistema não estão registrados. Não se infere equivalência computacional nem causa das diferenças.

Continuidade metodológica parcial: o protocolo-base é igual, mas o legado não contém prompts completos dos julgamentos ou revisões nem instruções de revisão. run02 contém dez prompts vinculados de julgamento e dez de revisão, com instruções próprias de auditoria. Há ainda um prompt Q03 Ágil v2, sem envio declarado, idêntico em bytes ao v1: o julgamento está ligado ao v1. sentAt registra declaração de envio, não prova independente. Não é possível comprovar igualdade dos prompts efetivamente usados entre rodadas.

## Conferência dos julgamentos e lacunas

Nos vinte pareceres integrais, os quarenta totais coincidem com a soma dos três critérios e os resultados seguem as notas e o A/B conferido. Não foi encontrada divergência numérica entre tabela e resultado. No legado não há pontuação estruturada; em run02 os campos estruturados estão vazios (null, critérios vazios, checked=false), embora os pareceres contenham notas. É uma lacuna de cadastro, não uma segunda pontuação ou nota zero. A inconsistência de classificação em Q04 Ágil do legado permanece registrada: o juiz atribuiu Parcialmente conforme ao ChatGPT, apesar de descrever contradição central; o revisor pede Divergente.

## Adversário fixo, avaliação variável

Com o ChatGPT byte a byte fixo, houve mudança de nota em cinco das dez séries entre execuções: Q02 contra Ágil 10 > 9; Q04 contra Ágil 6 > 4; Q04 contra Pleno 3 > 5; Q05 contra Ágil 4 > 3; Q05 contra Pleno 2 > 3. Não houve mudança nas demais. Contra Ágil, sua média passou de 7,0 a 6,2; contra Pleno, de 5,8 a 6,4. Isso é variação observada no julgamento, não mudança de resposta. A causa não foi isolada.

## Interpretação por pergunta e modo

Sínteses editoriais. Revisões antigas e novas permanecem separadas das notas originais.

**Q01 · Ágil: 2,0 > 3,0**

No legado, a revisão questionava Divergente e o uso de acréscimos não verificáveis. Na nova, ainda aponta penalização de assinatura a rogo, acertos ignorados e 0/2 pouco explicado; a preferência pelo ChatGPT tem suporte, mas a margem exige cautela.

**Q01 · Pleno: 5,0 > 6,0**

A revisão antiga corrigia a leitura da ressalva notarial e de citação do ChatGPT. A nova mostra que o Pleno já explicita ausência de transmissão, apontada como omissão; atualização nominal não é diferencial exclusivo. A margem de um ponto pode ser afetada.

**Q02 · Ágil: 2,0 > 7,0**

O legado sustentava a derrota por contradições explícitas. A nova revisão mostra comunicação independente de análise e síntese prática já presentes; questiona descontos, exigências além da referência e a diferença de dois pontos a favor do ChatGPT.

**Q02 · Pleno: 4,0 > 7,0**

A antiga revisão sustentava a incompletude do Pleno e questionava o 9 do ChatGPT. A nova identifica conteúdo semântico ignorado, condição de doação efetivamente citada e descontos por organização; a vantagem de dois pontos do ChatGPT não está suficientemente sustentada.

**Q03 · Ágil: 10,0 > 9,0**

No legado, a revisão aceitava o empate com tolerância à condição registral implícita. A nova questiona o único desconto e o tratamento de informação não verificável; sua reconsideração pode eliminar a vantagem do ChatGPT, sem alterar aqui o 10×9 original.

**Q03 · Pleno: 10,0 > 10,0**

A revisão antiga preservava os acréscimos como neutros. A nova corrige a supressão da ressalva no material recuperado e pede justificativa para a condição sem protocolo ou averbação. Não demonstra vantagem de um participante.

**Q04 · Ágil: 1,0 > 3,0**

A revisão antiga questionava a classificação do ChatGPT e a leitura de inventário a qualquer tempo. A nova pede correção da descrição do Ágil, aplicação da regra de zero à conclusão essencial e descontos separados; notas e margem continuam frágeis.

**Q04 · Pleno: 8,0 > 2,0**

A revisão antiga sustentava a vitória do Pleno, com possível desconto duplicado. A nova sustenta a preferência pelo ChatGPT, mas aponta contradição interna do Pleno omitida e critérios parciais apesar da regra de zero; a nota exata não está plenamente justificada.

**Q05 · Ágil: 8,0 > 7,0**

A revisão antiga sustentava vantagem nos requisitos e alertava para a validade não julgável. A nova explicita necessidade de inconclusividade global e documenta motivo normativo repetido em dois critérios. Não cria nova pontuação.

**Q05 · Pleno: 10,0 > 9,0**

A antiga revisão questionava o 10 do Pleno e Divergente do ChatGPT. A nova pede inconclusividade global pela validade ausente no gabarito e separação de acréscimos não verificáveis, incluindo documento original. Vantagem apenas nos requisitos não resolve o julgamento global.

## Conclusão limitada à amostra

Nesta amostra, Q02 mostra avanço de cobertura nos dois modos; Q01 do Pleno acrescenta os 90 dias, mas perde outros requisitos. Q04 do Pleno mostra regressão mais clara. Q05 combina ganhos e perdas, e Q03 Ágil tem queda causada por desconto questionado. As oscilações das notas do adversário fixo e os problemas de leitura, distribuição de pontos e inconclusividade impedem atribuir toda variação ao VadeChat. Sem prompts completos no legado, a continuidade do procedimento efetivo permanece parcialmente indocumentada. Não há conclusão sobre superioridade jurídica geral, custo, latência ou produtividade.

## Pendências e evidências

Lacunas metodológicas: prompts e instruções de revisão ausentes no legado; campos estruturados vazios no Run 02; descontos questionados e solicitação de inconclusividade global em Q05. As notas e os vencedores originais são preservados. Este relatório não produz novos julgamentos nem corrige o gabarito.

Página e textos integrais: https://relalia.github.io/relatorios/benchmark-comparativo-2026-10-14/. Índice gerado e hashes: /reports/benchmark-comparativo-2026-10-14-auditoria.json. Execução inicial: /relatorios/benchmark-2026-10-09/. 125 fontes pertinentes; backups e rascunhos excluídos.