Reteste VadeChat × Claude - Run 02 comparado à execução inicial

Execuções: 13/10/2026 (legado01) e 15/10/2026 (run02).

Q03 responde por +0,6 ponto da média do Ágil e +0,8 do Pleno, acima dos ganhos líquidos de +0,5 e +0,6. As outras quatro perguntas, em conjunto, reduzem as médias em 0,1 e 0,2 ponto. As respostas fixas do Claude receberam notas diferentes em quatro dos dez embates entre execuções. As séries contra Ágil e Pleno permanecem separadas. O avanço de cobertura mais claro ocorre em Q03. No Pleno, Q04 perde requisitos antes presentes; em Q05, a revisão contesta o julgamento inicial e considera defensável a nova vantagem, com ressalvas.

Execução exploratória com cinco perguntas. As notas medem concordância com a referência humana, sem validação jurídica independente ou demonstração de superioridade geral. As revisões por outra IA não constituem validação jurídica.

Modo	Média 13/10	Média 15/10	Variação	Subiram / caíram / iguais
Ágil	7,0	7,5	+0,5	2 / 2 / 1
Pleno	7,8	8,4	+0,6	2 / 3 / 0

Dez comparações de notas originais

Questão	Modo	VC antes	VC nova	Variação	Mudança principal
Q01	Ágil	5,5	4,5	-1,0	Acrescenta comprovação de quitação como condição; explicita risco de não registro.
Q01	Pleno	9,5	9,0	-0,5	Mantém CNIB, ciência e risco; torna categórica a dependência de cancelamento ou autorização.
Q02	Ágil	7,5	7,5	0,0	Amplia hipóteses de dispensa, mas não explicita a condição dos marcos confrontantes.
Q02	Pleno	8,5	7,5	-1,0	Distingue retificação de georreferenciamento e explicita § 3º, I e II; perde um ponto.
Q03	Ágil	7,0	10,0	+3,0	Passa a cobrir os quatro artigos, certidão histórica e prazos de 90 e 30 dias.
Q03	Pleno	6,0	10,0	+4,0	Substitui três dispositivos não localizados por cobertura dos quatro artigos e prazos.
Q04	Ágil	8,0	9,0	+1,0	Passa de CIF ou CIB para ambos e detalha saneamento; chama georreferenciamento urbano de facultativo.
Q04	Pleno	9,0	7,5	-1,5	Perde controle societário rural e hipótese urbana da Reurb; condiciona cadastros e localização.
Q05	Ágil	7,0	6,5	-0,5	Deixa de explicitar capacidade; enfatiza solidariedade e não individualiza poderes distintos.
Q05	Pleno	6,0	8,0	+2,0	Retira recomendação de instrumentos separados, mantém capacidade e acrescenta exemplos.

Médias de cinco notas presentes por modo e execução, sem arredondamento intermediário. Nenhuma ausência vira zero. São cinco perguntas em dez pares comparáveis, com vinte julgamentos históricos; não são dez perguntas distintas.

Resultados originais do VadeChat (vitórias / empates comuns / derrotas, sobre cinco embates): Ágil 3/0/2 > 3/0/2; Pleno 3/1/1 > 4/0/1. Não houve empate por abstenção, abstenção ou resultado inconclusivo originalmente atribuído. A única igualdade foi Q01 Pleno no Run 01.

Conferência de integridade

Participantes: VadeChat Ágil, VadeChat Pleno e Claude gratuito. Referência: respostas humanas fornecidas. Juiz declarado: ChatGPT Grátis, modelo não identificado. Revisor declarado: ChatGPT, modelo 6.1 Sol, nível Alto, acesso pago (GPT 6.1 Sol Alto). Claude declarado: Sonnet 5.5, nível Médio, acesso gratuito. São configurações registradas pelo executor, sem comprovação independente. Os campos de modelo do VadeChat não foram preenchidos.

Vínculos: os manifestos identificam o mesmo benchmark d5072482-72a6-4d5b-843a-32312e74da51 e execuções distintas. O Run 02 declara a execução inicial como anterior. Ordinais e rótulos foram conferidos com identidades, hashes, versões e dependências; nenhum conteúdo do benchmark com ChatGPT foi usado como referência.

Preservação: as cinco perguntas, cinco referências humanas, cinco respostas do Claude e cinco registros locais de alternância são idênticos byte a byte entre execuções, por SHA-256. Protocolo-base e alternância global também são idênticos. Não foram encontradas diferenças apenas de BOM, codificação ou quebras de linha nesses pares. As dez respostas do VadeChat, dez julgamentos e dez revisões mudaram.

Referências efetivas: os dez prompts registrados do Run 02 contêm exatamente a referência atual, incluindo metadados administrativos. Os campos separados de fatos e de prompt da referência estão vazios nas duas execuções. Q02 contém no próprio texto humano fato obrigatório e peso 1, além de observação de revisão sobre os §§ 1º-3º; Q05 contém menção ao Código Civil, peso 1. Esses trechos foram preservados, sem tratar metadados como parte substantiva da pergunta. No legado, a referência efetivamente enviada não pode ser comprovada sem os prompts completos.

Procedência declarada: as versões do Claude no Run 02 registram reaproveitamento, com execução, registro, versão e hash da origem. A cadeia foi conferida com o manifesto inicial e os textos publicados. Igualdade de conteúdo não comprova sozinha a procedência, e os registros locais não são prova independente de envio. As mesmas cinco respostas são utilizadas contra os dois modos.

Alternância: Claude ocupa A em Q01, Q03 e Q05; VadeChat ocupa A em Q02 e Q04. Os dez prompts novos, o protocolo, registros locais e o conteúdo dos pareceres são compatíveis. No legado, o campo administrativo de confirmação é falso; no Run 02 é verdadeiro. Não se presumiu uma posição fixa para o produto.

Continuidade parcial: os nomes e configurações declaradas de juiz e revisor coincidem entre execuções, assim como o protocolo-base. Os vinte prompts novos estão vinculados às respectivas versões de julgamento e revisão, com declaração de envio. O legado não contém prompts completos nem instruções de revisão, impossibilitando afirmar igualdade do material efetivamente enviado ou das instruções de auditoria.

Metadados: embora o Claude tenha modelo Sonnet 5.5 e o revisor tenha 6.1 Sol preenchidos, suas configurações também marcam unidentified=true. Essa inconsistência administrativa é preservada: os nomes são declarados pelo executor. O modelo do juiz ChatGPT Grátis permanece não identificado. Datas e identidades de execução mudaram legitimamente. A conferência cobre 154 arquivos no legado e 140 no Run 02; apenas documentos pertinentes à leitura e à auditoria integram os anexos.

Conferência dos julgamentos e lacunas

Escala original: conclusão e orientação prática 0-4; fundamentação e informações essenciais 0-4; condições, limites e ressalvas 0-2. Os quarenta totais dos vinte pareceres coincidem com a soma dos critérios, e os vencedores coincidem com as notas. As pontuações estruturadas do Run 02 estão vazias: as notas foram extraídas dos pareceres, sem converter ausência em zero. Classificação e resultado são transcritos, sem correção automática. Informações adicionais não verificáveis e fundamentação normativa diferente não devem receber prêmio ou desconto por si sós; extensão e número de citações não são métricas.

Adversário fixo, avaliação variável

Claude permaneceu byte a byte idêntico. Contra Ágil, Q04 mudou de 7,0 para 6,0 e Q05 de 7,5 para 8,0; contra Pleno, Q03 mudou de 5,5 para 3,5 e Q04 de 6,0 para 5,0. São quatro de dez embates. Suas médias foram 7,1 > 7,0 contra Ágil e 7,0 > 6,4 contra Pleno. Há também classificações alteradas sem mudança de nota, como Q02 contra Ágil (6,5: Parcialmente conforme > Divergente). A variação observada não isola sua causa e impede atribuir toda diferença ao VadeChat.

Interpretação por pergunta e modo

Sínteses editoriais. Revisões antigas e novas permanecem separadas das notas originais.

Q01 · Ágil: 5,5 > 4,5

A revisão antiga diferencia lavratura de registro. A nova questiona descontos por validade negocial não verificável e a classificação Parcialmente conforme diante de possível condição essencial divergente; a vantagem do Claude exige cautela.

Q01 · Pleno: 9,5 > 9,0

A revisão antiga rejeita exigir palavras exatas e já observa oscilação do Claude entre modos. A nova questiona penalização de autorização judicial não verificável e possível duplicação do desconto; a margem de 0,5 não fica bem sustentada.

Q02 · Ágil: 7,5 > 7,5

Ambas as revisões apontam assinatura técnica já presente e leitura discutível da negativa do Claude. A nova destaca a observação incorporada à referência, possível desconto repetido e aplicação inconsistente da regra de zero; a vantagem de 1,0 exige cautela.

Q02 · Pleno: 8,5 > 7,5

A revisão antiga já questionava a leitura limitada à resposta direta. A nova aponta assinatura técnica presente, tratamento desigual de fundamentos comuns às respostas e descontos por conteúdo não verificável; a perda não pode ser atribuída apenas a pior cobertura.

Q03 · Ágil: 7,0 > 10,0

A revisão antiga ressalva calibragem e informações adicionais neutras. A nova aponta ausência explícita dos 30 dias para certidão específica, além da ambiguidade de alcance dessa exigência no gabarito; questiona o 10 e o tratamento das condições do Claude.

Q03 · Pleno: 6,0 > 10,0

A revisão antiga já questionava a pequena margem e a calibragem do Claude. A nova contesta a nota máxima por omissão do prazo da certidão específica e possível restrição adicional; exige separar cautela genérica de condições efetivamente cobertas.

Q04 · Ágil: 8,0 > 9,0

A revisão antiga aponta CIF/CIB, critérios rurais e omissões do Claude. A nova questiona a condição urbana e se ela afetaria a classificação pela regra de divergência essencial. O aumento para 9,0 não resolve essa ressalva.

Q04 · Pleno: 9,0 > 7,5

A revisão antiga já apontava omissões adicionais e oscilação do Claude. A nova considera plausível menor cobertura, mas questiona a fundamentação do desconto em conclusão e condições potencialmente divergentes; não propõe resultado corrigido nesta apresentação.

Q05 · Ágil: 7,0 > 6,5

A revisão antiga questiona a pequena margem e o peso da citação ao Código Civil. A nova aponta desconto por solidariedade não verificável, comparação desigual das ressalvas e exemplos tratados como exigência; a diferença de 1,5 não fica plenamente sustentada.

Q05 · Pleno: 6,0 > 8,0

A revisão antiga aponta capacidade expressa ignorada, recomendação tratada como restrição e crédito a informação não verificável do Claude. A nova considera defensável a vantagem de 0,5, com ajuste da descrição da menção ao Código Civil e sem premiar extensão ou artigos diferentes.

Conclusão limitada à amostra

Nesta amostra, o VadeChat passou a cobrir mais elementos da referência sobre documentação societária em Q03, elevando as médias dos dois modos. O Pleno perdeu cobertura em Q04 e retirou uma recomendação questionada em Q05. O Ágil tornou mais restritiva a conclusão de Q01 e deixou de explicitar capacidade em Q05. As revisões limitam a confiança nas notas máximas e em algumas diferenças de pontuação; o adversário fixo também oscilou. Não há demonstração de melhoria geral, correção jurídica, custo-benefício ou economia de tempo.

Pendências e evidências

Lacunas reais: prompts e instruções de revisão ausentes no legado; continuidade metodológica apenas parcial; campos estruturados vazios no Run 02; flags de modelo contraditórias e descontos questionados pelos revisores. Não houve validação jurídica externa nem medição sistemática de custo, latência ou limites dos planos. Não foram produzidas novas respostas ou novos julgamentos para corrigir o histórico.

Página e textos integrais: https://relalia.github.io/relatorios/benchmark-comparativo-claude-2026-10-15/. Índice gerado e hashes: /reports/benchmark-comparativo-claude-2026-10-15-auditoria.json. Execução inicial: /relatorios/benchmark-claude-2026-10-13/. 125 fontes pertinentes; backups e rascunhos excluídos.