Benchmark VadeChat × Gemini 3.8 Flash

VadeChat · 2026-11-06 · Rodada final

Síntese de resultados · complementar ao original

Na rodada de 06/11/2026, VadeChat Ágil e Gemini 3.8 Flash empataram na média. O VadeChat Pleno ficou 1,00 ponto acima na média. Cada modo registrou duas vitórias, um empate e duas derrotas em cinco embates.

Rodada final na revisão 331 do PDF executivo, com os dez embates incluídos nas médias e zero revisões ou decisões pendentes.

Resultados do benchmark · fonte de 06/11/2026

Google / google/gemini-3.8-flash · Ágil e Pleno · Rodada 1

5 perguntas · 10 embates comparáveis · escala 0-10. Médias e resultados originais do juiz.

VadeChat Ágil 8,00

VadeChat Ágil · 8,00 / 10

Gemini 3.8 Flash · 8,00 / 10

Diferença: 0,00 pontos · n = 5

VadeChat Pleno 9,20

VadeChat Pleno · 9,20 / 10

Gemini 3.8 Flash · 8,20 / 10

Diferença: +1,00 pontos · n = 5

Modo	VadeChat	Gemini 3.8 Flash	V / E / D	Comparáveis
Ágil	8,00	8,00	2 / 1 / 2	5/5
Pleno	9,20	8,20	2 / 1 / 2	5/5

Médias com duas casas conforme as conclusões da p. 4. Os valores por critério seguem o arredondamento da fonte.

Os resultados descrevem os dez embates destas cinco perguntas. Cada modo tem sua própria série de notas do adversário.

Onde os pontos foram obtidos

Critério	Máximo	Ágil · VC / adversário	Pleno · VC / adversário
C1 · Conclusão e orientação prática	4	3,6 / 3,8	4,0 / 3,8
C2 · Fundamentação e informações essenciais	4	3,4 / 3,0	3,4 / 3,0
C3 · Condições, limites e ressalvas	2	1,0 / 1,2	1,8 / 1,4

Base por modo e critério: Ágil n = 5; Pleno n = 5. Médias arredondadas por critério não devem ser somadas para reconstruir os totais.

Prioridades para a equipe de IA

Síntese editorial dos agregados; não constitui novo julgamento.

Empate na média do Ágil: A vantagem do VadeChat em C2 foi de 0,4 ponto. O Gemini teve 0,2 ponto a mais em C1 e 0,2 ponto a mais em C3, levando ao empate de 8,00 na média.

Diferença de média no Pleno: O VadeChat obteve média maior nos três critérios. A vantagem total foi de 1,00 ponto, com placar de duas vitórias, um empate e duas derrotas.

Revisões concluídas: As dez revisões foram concluídas. O executivo registra duas contestações no Ágil e uma no Pleno, com zero decisões pendentes.

Papéis e limites

Produto avaliado · Ágil e Pleno: VadeChat · modelo interno não informado.

Adversário: google · google/gemini-3.8-flash.

Juiz: OpenAI · openai/gpt-6.1-sol.

Revisor: Anthropic · anthropic/claude-sonnet-5.5.

Ágil · registro do PDF: Revisões 5/5 (0 pendentes); contestações 2; decisões pendentes 0. Contradições essenciais VC/adversário: 0/0; abstenções: 0/0. Julgamentos pendentes/inconclusivos/desatualizados: 0/0/0.

Pleno · registro do PDF: Revisões 5/5 (0 pendentes); contestações 1; decisões pendentes 0. Contradições essenciais VC/adversário: 0/0; abstenções: 0/0. Julgamentos pendentes/inconclusivos/desatualizados: 0/0/0.

Revisões não substituem as notas originais. Vencer em pontos não equivale à classificação Conforme. Ausência de sinalização não comprova ausência de erros.

Operação e consumo

Papel	Tentativas / falhas ou incertas	Tokens totais	US$ provedor	Durações somadas
Adversário	5 / 0	9.861	0,036406	96,4 s
Juiz	10 / 0	62.604	0,231817	158,2 s
Revisor	10 / 0	97.491	0,277718	125,0 s

Geração Tri7: Ágil 5 tentativas; Pleno 5 tentativas. Tokens, custo e duração não informados. Tentativas não representam perguntas avaliadas.

Os subtotais cobrem as tentativas do plano atual. A duração é a soma das tentativas. Os custos da geração Tri7 são desconhecidos.

Fonte preservada: https://relalia.github.io/originals/reports/benchmark-gemini-3-8-flash-2026-11-06-results.pdf

A fonte executiva consolida notas, cobertura e contestações. O anexo remete ao aplicativo e ao relatório técnico completo para evidências, versões, prompts e histórico.