Benchmarks e melhorias de interface - síntese de 16/10/2026

Execuções em 09 e 14/10 (ChatGPT) e 13 e 15/10/2026 (Claude). São duas observações por conjunto, dentro do período de 09 a 15/10; não há uma série diária de quatorze dias. As capturas pertencem à rodada de 16/10.

Cinco perguntas por benchmark. Notas de concordância com referências humanas, sem validação jurídica independente. Conjuntos e juízes diferentes; esta figura não representa um confronto direto entre ChatGPT e Claude nem um ranking geral.

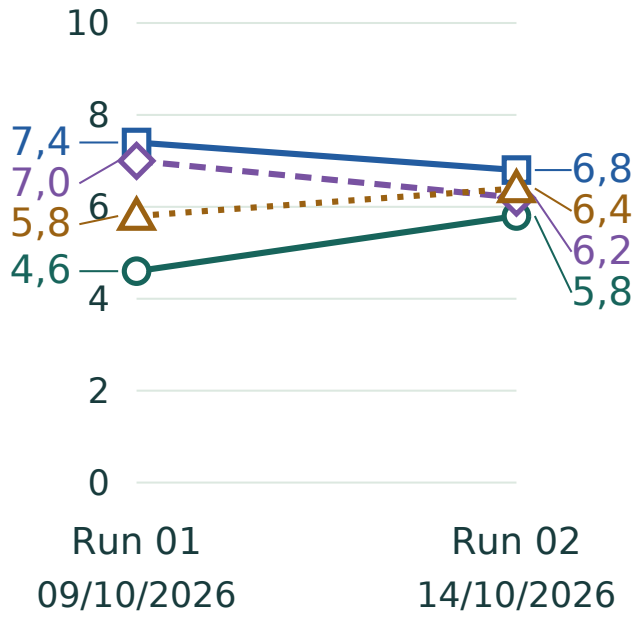
Conjunto	Modo	Run 01	Run 02	Dif. média	Subiram / caíram / iguais
VadeChat × ChatGPT	Ágil	4,6	5,8	+1,2	3 / 2 / 0
VadeChat × ChatGPT	Pleno	7,4	6,8	-0,6	2 / 2 / 1
VadeChat × Claude	Ágil	7,0	7,5	+0,5	2 / 2 / 1
VadeChat × Claude	Pleno	7,8	8,4	+0,6	2 / 3 / 0

Denominador: cinco notas válidas, nas mesmas perguntas, em cada modo e execução. Sem arredondamento intermediário.

Médias por execução · escala comum de 0 a 10

VadeChat × ChatGPT

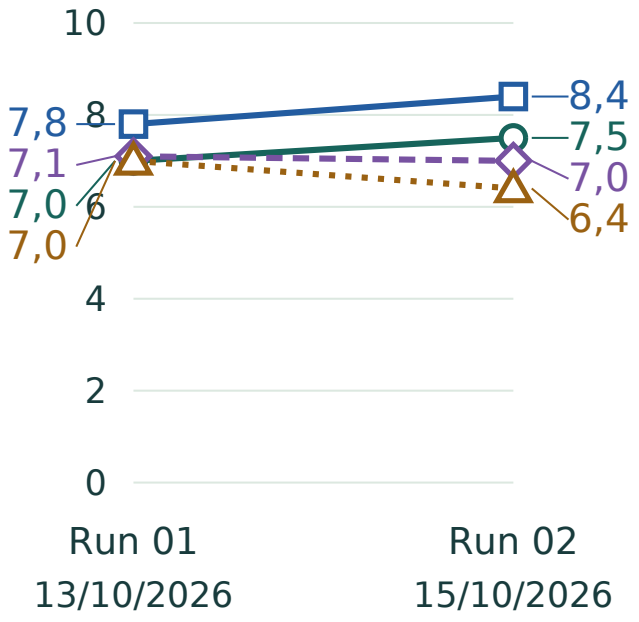
Juiz: Claude Sonnet 5.5 Médio · acesso gratuito declarado



Série	Run 01	Run 02	Dif.
VadeChat Ágil	4,6	5,8	+1,2
VadeChat Pleno	7,4	6,8	-0,6
ChatGPT gratuito contra Ágil	7,0	6,2	-0,8
ChatGPT gratuito contra Pleno	5,8	6,4	+0,6

VadeChat × Claude

Juiz: ChatGPT Grátis · modelo não identificado



Série	Run 01	Run 02	Dif.
VadeChat Ágil	7,0	7,5	+0,5
VadeChat Pleno	7,8	8,4	+0,6
Claude gratuito contra Ágil	7,1	7,0	-0,1
Claude gratuito contra Pleno	7,0	6,4	-0,6

Ágil: círculo e verde; Pleno: quadrado e azul. Adversário contra Ágil: losango e tracejado roxo; contra Pleno: triângulo e pontilhado ocre. Rótulos próximos usam linhas-guia, sem deslocar os pontos.

Segmentos retos ligam apenas Run 01 e Run 02 da mesma série. Não há interpolação temporal, tendência estimada ou comparação direta entre os conjuntos.

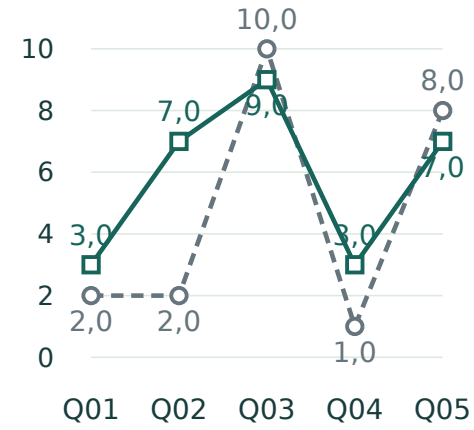
Por pergunta: onde a nota mudou

VadeChat · Run 01: círculo e tracejado cinza. Run 02: quadrado e linha verde (Ágil) ou azul (Pleno). Escala 0-10 nos quatro gráficos.

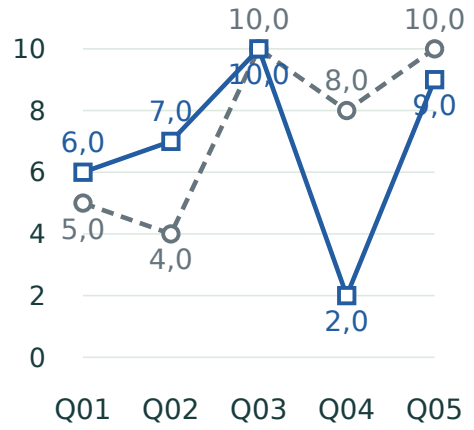
Condições declaradas: participante ChatGPT gratuito sem login, modelo não identificado; participante Claude gratuito com login e Sonnet 5.5 Médio exibido. Revisões de GPT 6.1 Sol Alto, acesso pago. Juízes distintos, identificados no painel de cada conjunto. Não são afirmações sobre condições atuais das plataformas.

VadeChat × ChatGPT

Ágil



Pleno

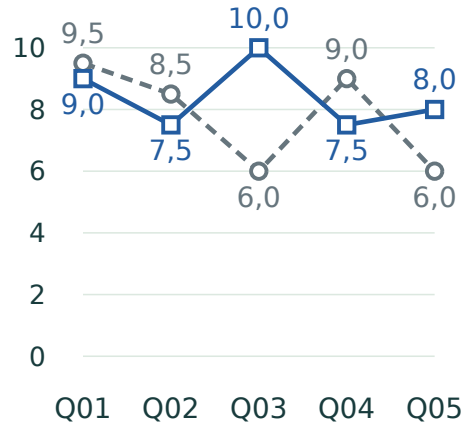


VadeChat × Claude

Ágil



Pleno



VadeChat × ChatGPT

No Ágil, Q02 soma +5 pontos, ou +1,0 da média: a maior parte do ganho líquido de +1,2. No Pleno, Q02 contribui +0,6, mas Q04 retira 1,2 ponto da média; o saldo é -0,6.

Adversário fixo: 5/10 embates com alteração. Q02 Ágil: 10,0 > 9,0; Q04 Ágil: 6,0 > 4,0; Q04 Pleno: 3,0 > 5,0; Q05 Ágil: 4,0 > 3,0; Q05 Pleno: 2,0 > 3,0.

Revisões - síntese editorial: As revisões questionam descontos e a sustentação de diferenças de pontuação. Em Q05, solicitam inconclusividade global quanto à validade da ficha, mantendo apenas uma comparação delimitada dos requisitos. Os resultados originais continuam no histórico; a revisão não os substitui.

VadeChat × Claude

Q03 contribui +0,6 à média do Ágil e +0,8 à do Pleno, acima dos ganhos líquidos de +0,5 e +0,6. As outras quatro perguntas somadas reduzem essas médias em 0,1 e 0,2 ponto. No Pleno, Q04 perde cobertura.

Adversário fixo: 4/10 embates com alteração. Q03 Pleno: 5,5 > 3,5; Q04 Ágil: 7,0 > 6,0; Q04 Pleno: 6,0 > 5,0; Q05 Ágil: 7,5 > 8,0.

Revisões - síntese editorial: As revisões questionam as notas máximas de Q03 e alguns descontos e margens. O prazo de 30 dias da simplificada para incorporação já existia no Ágil inicial; a dispensa do art. 808 já era desenvolvida no Pleno. O reteste amplia outros pontos e reformula esse conteúdo. Permanece separada a ressalva sobre o prazo atribuído à certidão específica pela referência.

Notas, classificações e vencedores originais preservados. Informações adicionais não verificáveis, extensão e número de citações não são métricas. As revisões questionam julgamentos; não substituem o histórico.

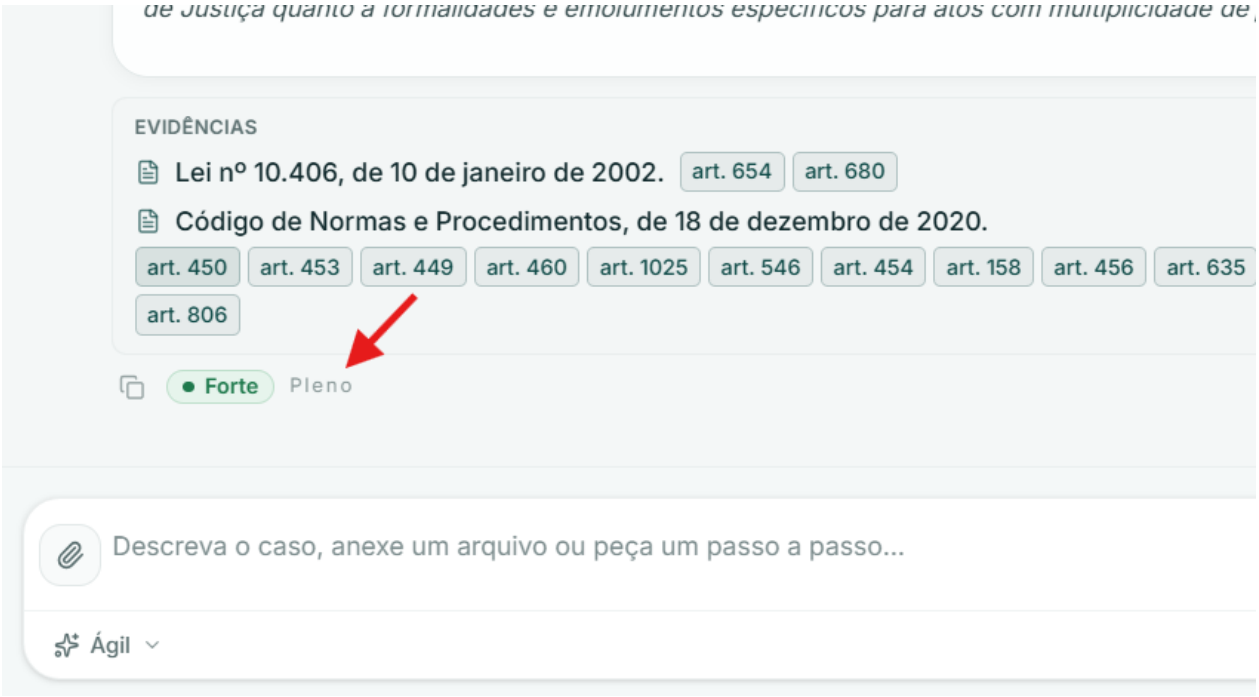
Interface: rastreabilidade por resposta

VC-UI-16A · Atendimento parcial documentado

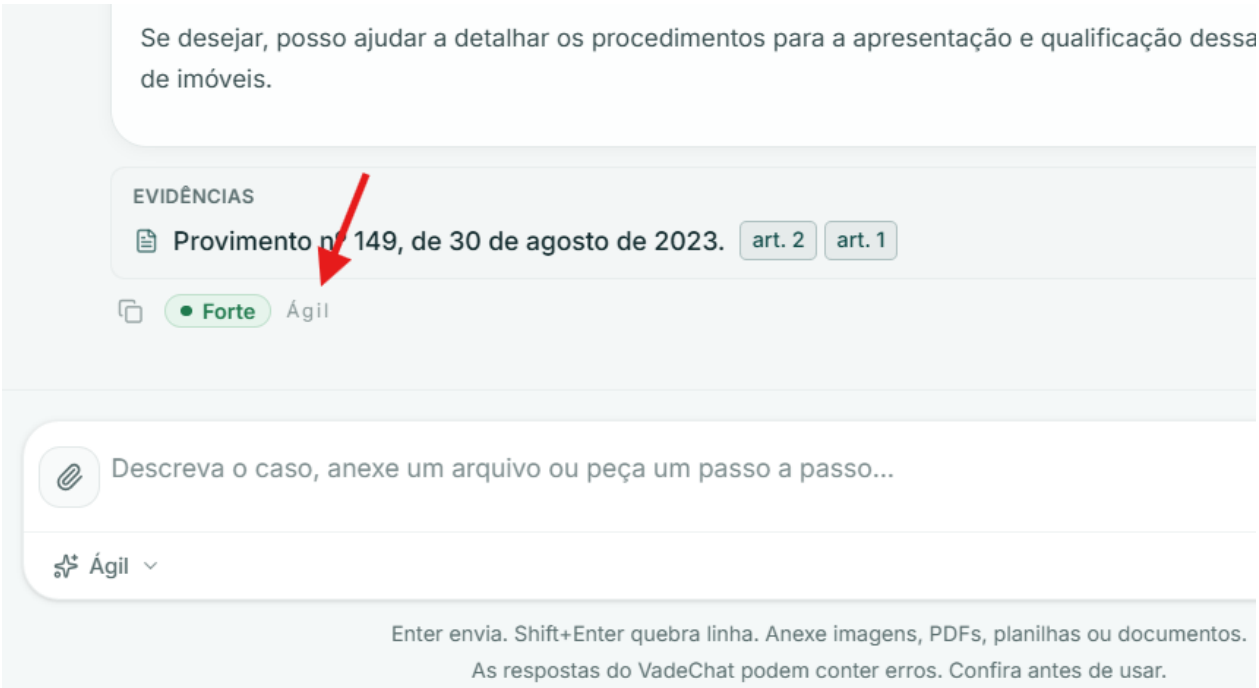
As capturas 1 e 2 exibem Pleno e Ágil junto aos controles das respectivas respostas. Na captura 1, a resposta indica Pleno enquanto o compositor está em Ágil.

Permite reconhecer o modo associado a cada resposta mesmo após mudar a seleção do compositor; melhora a rastreabilidade para o usuário.

Atende à indicação do modo no escopo de VC-TRACE-14. Modelo interno, regeneração, persistência ao reabrir e execução do backend não são demonstrados.



ALIA16-EV-01 · captura original · SHA-256 f9600d80575fda6f… (completo no índice)



ALIA16-EV-02 · captura original · SHA-256 579e8eb95d5e5517… (completo no índice)

Fonte: capturas e relato do usuário. Sem reteste independente do produto. Vínculo anterior: alia-2026-10-08 / VC-TRACE-14.

GIRO: leitura e ação em destaque

GIRO-UI-16B · Atendimento parcial documentado

A captura 3 mostra o controle Mostrar mais e um botão rotulado Perguntar ao VadeChat, visualmente maior que a ação compacta documentada anteriormente.



ALIA16-EV-03 · captura original · SHA-256 9dac089ded86ebe4… (completo no índice)

Relato do usuário: Mostrar mais expande o resumo e o botão ganhou área de interação. Benefício esperado: facilitar leitura e toque; sem medição de cliques ou velocidade. O escopo GIRO-UX-01 permanece parcialmente documentado.

Compositor: espaço para o contexto da notícia

VC-UI-16C · Atendimento parcial documentado

A captura 4 mostra a mensagem pré-inserida sobre a notícia em um campo ampliado, com rolagem interna. Parte do conteúdo continua fora da área visível.



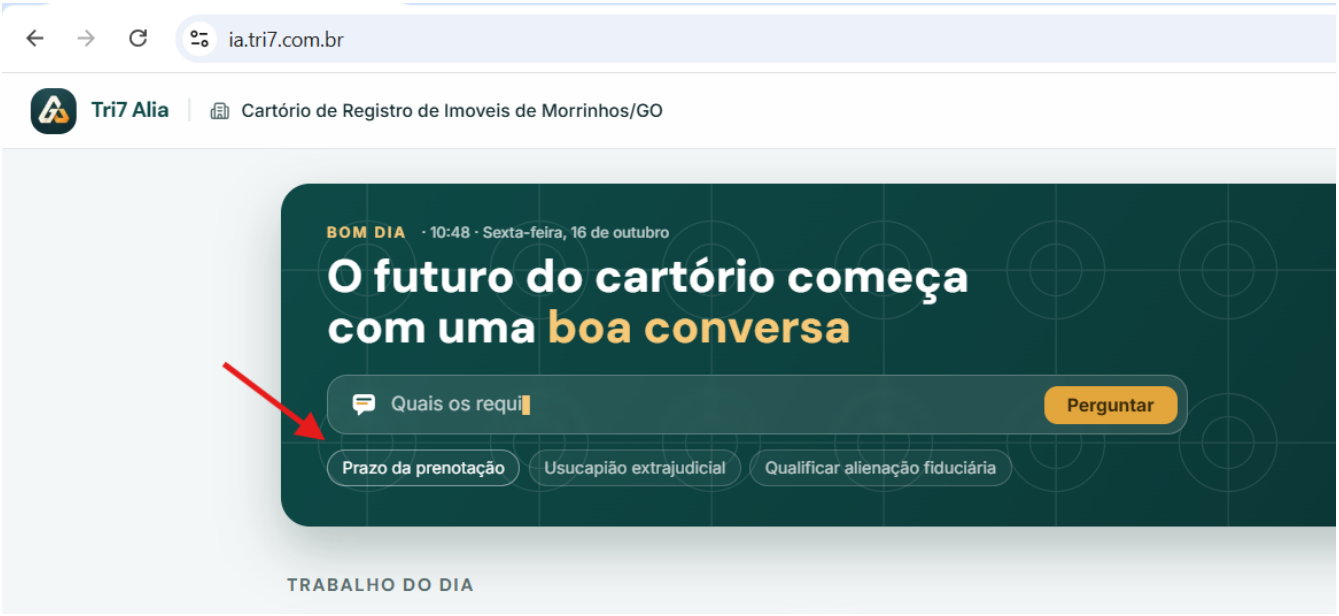
ALIA16-EV-04 · captura original · SHA-256 25320905d2300227… (completo no índice)

Altura adequada ao texto, segundo o usuário; mais espaço para edição, com rolagem. Não demonstra conteúdo todo visível, altura ilimitada, envio automático ou retorno ao tamanho inicial (VC-UX-05 / VC-FLOW-06).

Hero: do chip ao início da consulta

VC-UI-16D · Atendimento parcial documentado

As capturas 5 e 6 mostram o chip Prazo da prenotação na tela inicial, sua mensagem enviada na conversa e o estado Pesquisando na base.



ALIA16-EV-05 · captura original · SHA-256 aa705f8eec06980e... (completo no índice)



ALIA16-EV-06 · captura original · SHA-256 1e5f52943a423d30... (completo no índice)

Segundo o usuário, clicar no chip já inicia a conversa com seu conteúdo. As imagens são compatíveis com essa sequência, mas não registram o clique em si.

Reduz as etapas para iniciar a consulta com uma sugestão, sem medição de tempo.

O carregamento não comprova resposta concluída. O achado VC-UX-02 também abrangia texto digitado, Enter, envio único e recuperação de erro; seu escopo completo não pode ser marcado como resolvido.

Método, fontes e limites

Média = soma das notas válidas / quantidade utilizada. Variação = média do Run 02 - média do Run 01, nas mesmas perguntas. Contribuição por pergunta = diferença da nota / 5.

Referências humanas sem validação jurídica externa; conjuntos e juízes distintos. Prompts completos ausentes nos legados e metadados com lacunas. Configurações declaradas pelo executor. Não há evidência causal entre interface e notas, nem medição de custo, latência ou produtividade.

Página, ampliações das imagens e downloads: https://relalia.github.io/relatorios/sintese-benchmarks-interface-2026-10-16/. Dados: /reports/sintese-benchmarks-interface-2026-10-16-dados.json. Índice gerado e hashes: /reports/sintese-benchmarks-interface-2026-10-16-fontes.json. Comparativos completos: /relatorios/benchmark-comparativo-2026-10-14/ e /relatorios/benchmark-comparativo-claude-2026-10-15/.