VadeChat · resultados do benchmark e UX

VadeChat · 2026-11-02 · Registro final · resultados e proposta de UX

Relatório de 02/11/2026 · resultados e UX

Síntese de resultados da rodada de benchmark datada de 28/10/2026, incluída no relatório de 02/11/2026. VadeChat obteve médias superiores ao adversário nos dois modos desta amostra. A página destaca notas, critérios, resultados e pontos para a equipe de IA, seguida da proposta de UX para mensagens longas.

Resultados do benchmark · fonte de 28/10/2026

GPT-5.4 Mini com raciocínio ativado · Ágil e Pleno · Rodada 1

3 perguntas · 6 embates comparáveis · escala 0-10. Médias e resultados originais do juiz.

VadeChat Ágil 7,00

VadeChat Ágil · 7,00 / 10

GPT-5.4 Mini · 4,00 / 10

Diferença: +3,00 pontos · n = 3

VadeChat Pleno 6,67

VadeChat Pleno · 6,67 / 10

GPT-5.4 Mini · 5,00 / 10

Diferença: +1,67 pontos · n = 3

Modo	VadeChat	GPT-5.4 Mini	V / E / D	Comparáveis
Ágil	7,00	4,00	3 / 0 / 0	3/3
Pleno	6,67	5,00	2 / 0 / 1	3/3

Médias com duas casas conforme as conclusões da p. 3; o gráfico da p. 1 arredonda o Pleno para 6,7. Diferenças calculadas sobre as médias publicadas. Critérios arredondados na fonte; seus valores exibidos não devem ser somados para recalcular os totais.

Amostra de três perguntas, sem validação jurídica independente nesta síntese. As notas originais não demonstram superioridade geral; zero contradições essenciais registradas não comprova ausência de outros erros.

Onde os pontos foram obtidos

Critério	Máximo	Ágil · VC / adversário	Pleno · VC / adversário
C1 · Conclusão e orientação prática	4	3,0 / 2,3	2,7 / 2,3
C2 · Fundamentação e informações essenciais	4	3,0 / 1,3	2,7 / 2,0
C3 · Condições, limites e ressalvas	2	1,0 / 0,3	1,3 / 0,7

n = 3 por modo e critério. Médias arredondadas por critério não devem ser somadas para reconstruir os totais.

Prioridades para a equipe de IA

Síntese editorial dos agregados; não constitui novo julgamento.

Condições, limites e ressalvas

As médias de C3 são 1,0/2 no Ágil e 1,3/2 no Pleno. É uma dimensão a revisar nas respostas e justificativas originais antes de definir ajustes na IA.

Entender a derrota do Pleno

O Pleno perdeu um dos três embates. O executivo não identifica a pergunta nem a justificativa dessa derrota; esse caso precisa ser localizado no relatório técnico para orientar uma correção específica.

Investigar o histórico de tentativas

A fonte registra 27 tentativas de geração no Ágil e três no Pleno, além de duas falhas/incertas no juiz e duas no revisor. São contagens operacionais, separadas dos três embates avaliados por modo; o anexo não explica suas causas.

Papéis e limites

Produto avaliado · Ágil e Pleno: VadeChat · modelo interno não informado.

Adversário: OpenAI · openai/gpt-5.4-mini. Raciocínio ativado, conforme o título do executivo. A modalidade de acesso não é identificada como plano gratuito.

Juiz: OpenRouter API · anthropic/claude-sonnet-5.5.

Revisor: OpenRouter API · openai/gpt-5.4-mini. Papel separado do adversário; revisões não substituem as notas do juiz.

Revisões: 3/3 por modo; nenhuma pendente. Contradições essenciais e abstenções registradas: 0 para ambos os participantes, nos dois modos. Contestações, decisões pendentes e julgamentos pendentes, inconclusivos ou desatualizados: 0. Vencer em pontos não equivale à classificação Conforme. Ausência de sinalização não comprova ausência de erros.

Operação e consumo

Papel	Tentativas / falhas ou incertas	Tokens totais	US$ provedor	Durações somadas
Adversário	3 / 0	3.502	0,015343	29,8 s
Juiz	8 / 2	98.326	0,370452	151,9 s
Revisor	8 / 2	71.041	0,132123	165,3 s

Geração Tri7: Ágil 27 tentativas; Pleno 3 tentativas. Tokens, custo e duração não informados. Tentativas não representam perguntas avaliadas.

Subtotais disponíveis do plano atual, com falhas de consumo registrado incluídas e adversário compartilhado contado uma vez por tentativa. Duração é a soma das tentativas, não latência da resposta. Tokens de cache e raciocínio não são somados novamente. Custos, tokens e duração da geração Tri7 são desconhecidos; estes valores não representam o custo total do VadeChat.

Fonte preservada: https://relalia.github.io/originals/reports/benchmark-2026-10-28-results.pdf

A fonte executiva não inclui textos das perguntas, referências, pareceres individuais, comentários dos revisores ou histórico das tentativas. Esses registros são necessários para explicar causas e propor correções específicas. Declarações de envio não são prova independente de execução; a revisão também não é validação jurídica independente.

Esta ficha é complementar. Os documentos originais estão disponíveis separadamente, com bytes preservados.

UX do VadeChat · 1 proposta

VC-MSG-01 · Recolher mensagens muito longas por padrão, com acesso ao texto integral

Vídeo do caso e referência fornecida: O vídeo mostra a rolagem por vários trechos de uma mensagem longa, cujo balão ocupa quase toda a área disponível da conversa. A captura de referência apresenta uma prévia do texto com o controle “Mostrar mais” no próprio balão. O usuário solicita adotar esse padrão para evitar que mensagens muito grandes ocupem espaço excessivo. A imagem mostra o controle, sem demonstrar sua expansão ou recolhimento.

Categoria: VadeChat / conversa / visualização de mensagens

Contexto: Mensagem extensa enviada pelo usuário, demonstrada no vídeo; captura com “Mostrar mais” como referência visual.

Melhoria esperada: Apresentar mensagens muito extensas recolhidas inicialmente, com uma prévia de altura limitada, inspirada na captura e adaptada à tela. “Mostrar mais” deve revelar o texto integral; “Mostrar menos” deve permitir recolhê-lo novamente. Preservar o conteúdo completo para envio, armazenamento e cópia.

Sugestão registrada: Usar um controle de expansão no próprio balão, com estado aberto ou fechado identificável. Evitar que o recolhimento provoque um salto que faça o usuário perder a mensagem na conversa. Manter mensagens curtas sem controles desnecessários e ajustar a prévia em celular e desktop.

Como verificar: Após implementação, testar mensagens curtas e extensas, inclusive texto colado e multilinha. Conferir expansão integral, recolhimento, posição de leitura e cópia sem perda de conteúdo. Testar teclado, foco, indicação acessível do estado e telas pequenas. Verificar a abertura da conversa e novas mensagens longas. Nenhum reteste foi executado nesta rodada.

Situação: Proposta de melhoria

Reteste: Ainda não aplicável à proposta

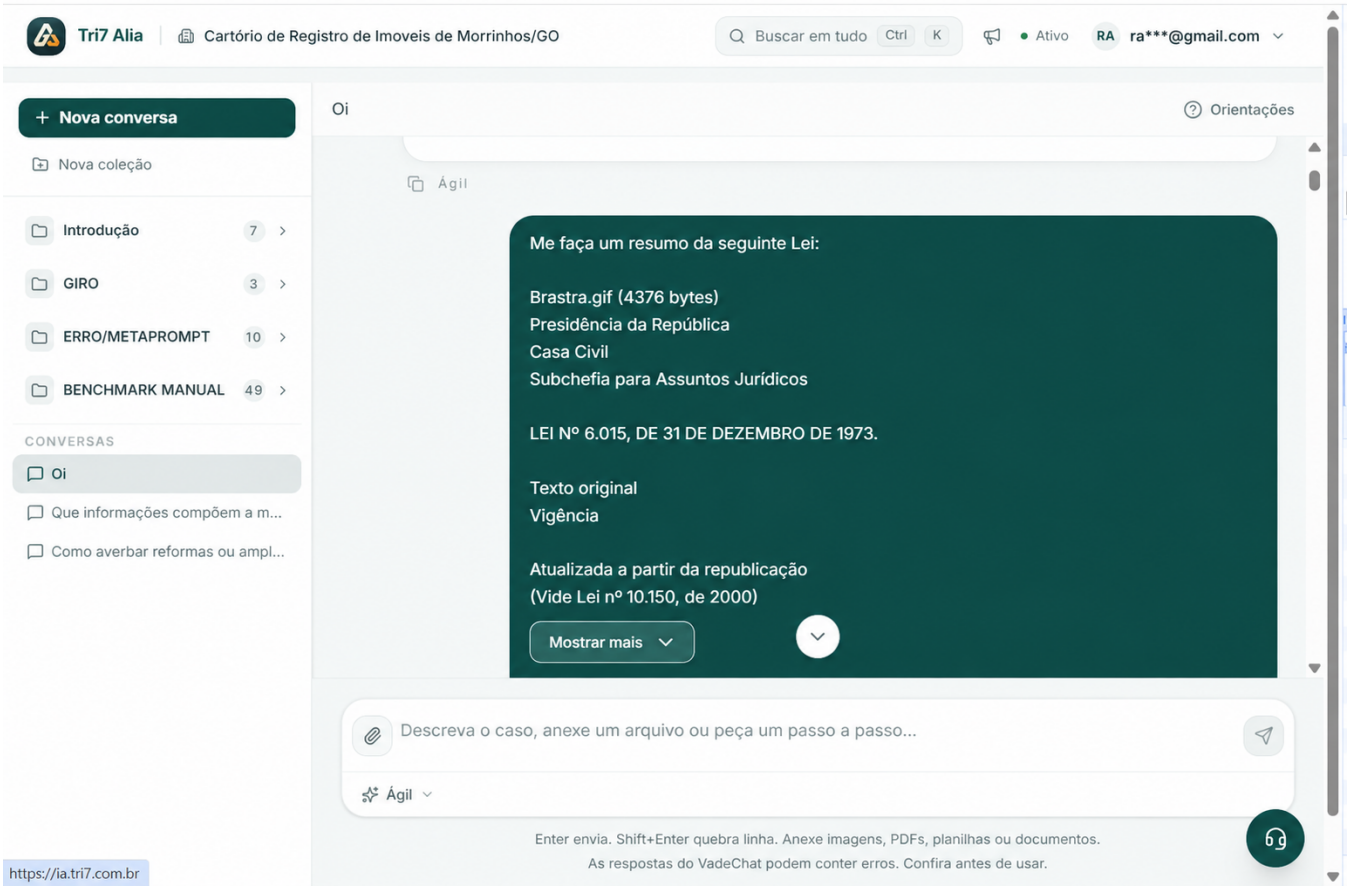
Resultado do reteste: Sem resultado de reteste registrado

Evidência: VCUX1102-EV-01 · Vídeo original do caso: rolagem por trechos de uma mensagem extensa no histórico do VadeChat, com grande ocupação vertical do balão. O arquivo foi preservado integralmente, incluindo áudio; os quadros usados para inspeção não integram os anexos do relatório.

Vídeo original · VCUX1102-EV-01 · 20261102-1302-10.4990402.mp4. Consulte o MP4 no portal; este PDF não contém quadros extraídos.

https://relalia.github.io/originals/evidence/vadechat-ux-2026-11-02/mensagem-longa-rolagem.mp4

Evidência: VCUX1102-EV-02 · Referência visual fornecida pelo usuário: balão com prévia do texto e botão “Mostrar mais”. O controle “Mostrar menos” faz parte da proposta, não é demonstrado nesta captura.



Captura original · VCUX1102-EV-02 · codex-clipboard-33043117-f41b-4f6b-a39d-6bcef5f7f5e2.png

https://relalia.github.io/originals/evidence/vadechat-ux-2026-11-02/mensagem-recolhida-referencia.png

Resultados transcritos do PDF executivo fornecido, preservado como anexo original. A data de 28/10 é a data da rodada na fonte; esta publicação integra o relatório de 02/11. Perguntas, referências, notas individuais e pareceres completos não vieram neste anexo. A síntese não reavalia respostas nem confirma correção jurídica. O vídeo e a captura de UX são evidências do caso e referência visual; a funcionalidade proposta não foi implementada ou retestada no VadeChat nesta rodada.